

3 KI in der Messtechnik

Künstliche Intelligenz hat die Messtechnik erheblich verändert, insbesondere durch Computer-Vision-Methoden wie Convolutional Neural Networks. Diese Netzwerke ermöglichen eine präzise Objektllokalisierung innerhalb von Bildern und erleichtern automatisierte Messungen in komplexen Umgebungen. Schlüsselaufgaben wie die Erstellung von Datensätzen, Bildbeschriftung und Datenaugmentation verbessern die Modellgenauigkeit und Widerstandsfähigkeit gegenüber Herausforderungen wie Beleuchtungsinkonsistenzen und Verdeckungen. Fortschrittliche Architekturen wie "You Only Look Once" und "Residual Network" mit Regressionsköpfen werden häufig zur Koordinatenschätzung und Schlüsselpunktdetektion eingesetzt. Über die Objektllokalisierung hinaus verbessert Künstliche Intelligenz Echtzeit-Messsysteme durch Unterdrückung von Signalrauschen, Kalibrierung von Sensoren und Anomalieerkennung, wodurch eine verbesserte Zuverlässigkeit und Betriebseffizienz gewährleistet wird. Industrien nutzen Künstliche Intelligenz für vorausschauende Diagnosen, die Optimierung von Messprozessen und die Rationalisierung von Arbeitsabläufen. Applications of Convolutional Neural Networks span across object localization using YOLO and Faster Region-Based Convolutional Neural Network (Faster R-CNN), as well as Denoising, calibration, and anomaly detection. These technologies, once theoretical, are now integral to smart factories, precision agriculture, transportation, and infrastructure monitoring. [14]

Künstliche Intelligenz hat sich von einem theoretischen Feld zu einer transformativen Kraft in verschiedenen Bereichen entwickelt, angetrieben durch Maschinelles Lernen und dessen Unterfeld, Deep Learning. Neuronale Netze, inspiriert von der Gehirnstruktur, bilden die Grundlage moderner KI-Lösungen. Dieses Kapitel untersucht, wie Convolutional Neural Networks Messtechnologien revolutioniert haben und über konventionelle manuelle Kalibrierung und vordefinierte Modellierung hinausgehen. Deep Learning ermöglicht es Modellen, umfangreiche Datenströme autonom zu verarbeiten, sich dynamisch anzupassen und mit größerer Fehlertoleranz zu arbeiten. Anwendungen von Convolutional Neural Networks umfassen die Objektllokalisierung mittels YOLO und Faster Region-Based Convolutional Neural Network (Faster R-CNN) sowie Entrauschung, Kalibrierung und Anomalieerkennung. Diese Technologien, einst theoretisch, sind heute integraler Bestandteil von Smart Factories, Präzisionslandwirtschaft, Transport und Infrastrukturüberwachung. [17]

3.1 Objektllokalisierung mittels Computer Vision

Die Objektllokalisierung spielt eine entscheidende Rolle in der Assistenztechnologie für sehbehinderte Personen (VIPs). Computer-Vision-basierte Systeme nutzen Tiefenkameras, RGB-Sensoren und Algorithmen des maschinellen Lernens, um Hindernisse zu erkennen und den Benutzern Echtzeit-Feedback zu geben. Die Positionsschätzung ist eine grundlegende Aufgabe in der Messtechnik, da sie Anwendungen in der Robotik, autonomen Navigation, Augmented Reality und Assistenztechnologien für sehbehinderte Personen findet. Traditionelle Methoden

basieren auf Sensorfusion und geometrischen Computer-Vision-Techniken. Diese Ansätze haben jedoch oft Schwierigkeiten in dynamischen Umgebungen aufgrund von Rauschen, Verdeckungen und Rechenkomplexität. Convolutional Neural Networks (CNNs) haben sich als leistungsstarke Alternative erwiesen, die ein End to End Lernen räumlicher Beziehungen aus visuellen Daten ermöglicht. Im Gegensatz zu klassischen Methoden können CNNs Objektpositionen direkt aus Rohbildern vorhersagen, wodurch die Abhängigkeit von handgefertigten Merkmalen reduziert wird. Dieser Abschnitt untersucht, wie CNNs für die Positionsschätzung angewendet werden, wobei der Schwerpunkt auf Architekturdesign, Trainingsmethoden und realen Implementierungen liegt. [30]

Mehrere Studien haben fortgeschrittene Lokalisierungstechniken untersucht:

- **Kinect-Tiefenkameras:** Diese Systeme analysieren Tiefenkarten, um Objektpositionen und -entfernungen zu bestimmen und die Genauigkeit der Hinderniserkennung zu verbessern.
- **Ultraschall- und RGB-Kamera-basierte Systeme:** Geräte integrieren Ultraschallsensoren mit RGB-Kameras, um die Lokalisierungspräzision zu verbessern und Feedback über Audio- oder haptische Signale zu geben.
- **Algorithmen des maschinellen Lernens:** Ansätze wie CNN, YOLO (You Only Look Once) und SVM (Support Vector Machine) wurden verwendet, um die Objekterkennung und das räumliche Bewusstsein zu verbessern. Diese Systeme erzeugen 3D-Darstellungen der Umgebung und verbessern so die Fähigkeit des Benutzers, sich sicher zu navigieren.
- **Tragbare Systeme:** Einige Assistenztechnologien integrieren Smart Glasses, mobile Apps oder am Kopf getragene Geräte mit Deep-Learning-Modellen, um Hindernisse zu erkennen und zu lokalisieren. Diese Systeme erreichen hohe Genauigkeitsraten und helfen VIPs, Kollisionen in dynamischen Umgebungen zu vermeiden.
- **Semantische Objekterkennung & Tiefenkarten:** Durch die Kombination von Objekterkennung mit Tiefenschätzung ermöglichen einige Lösungen Benutzern, zwischen verschiedenen Arten von Hindernissen zu unterscheiden und deren Nähe in Echtzeit zu beurteilen. [26]

Assistive Technologien für sehbehinderte Menschen lassen sich in drei Hauptkategorieinteilen: **Objekterkennungsgeräte**, **Navigationssysteme** und **Hybridgeräte**, die beide Funktionen kombinieren. Diese Systeme vermitteln Informationen durch Ton oder Vibration und unterstützen Nutzer dabei, Hindernisse zu erkennen und sich sicher in ihrer Umgebung zu bewegen.

Objekterkennungsgeräte

Diese Geräte nutzen Sensoren, Ultraschallsysteme oder Kameras, um Umgebungsdaten zu erfassen und dem Nutzer Feedback zu geben [37]:

- **Kinect-Tiefenkameras und Ultraschallstöcke** erkennen Hindernisse und berechnen deren Entfernung mithilfe adaptiver Schwellenwerte oder Schallwellen.
- **Multisensorsysteme** setzen maschinelles Lernen (z. B. SVM, CNN) zur Objekterkennung ein und liefern akustisches oder haptisches Feedback.
- **Tragbare Lösungen** wie Brillen oder Smartphone-basierte Deep-Learning-Modelle erreichen eine hohe Genauigkeit bei der Hinderniserkennung.

Navigationssysteme

Navigationshilfen leiten VIPs mithilfe von **GPS, RFID und AR-Technologien**:

- **Geräte mit RGB-D-Sensoren** unterstützen Nutzer durch Tiefen- und Farbinformationen.
- **Einige Wearables** nutzen Sprachausgabe, haptische Signale oder Audiodaten für Echtzeitführung.
- **Bildgestützte Systeme** helfen beim Joggen, Laufen und Gehen, z. B. durch Handschuhe mit Bewegungserkennung [33].

Hybridsysteme

Diese kombinieren Objekterkennung und Navigation für eine verbesserte Mobilität:

- **Intelligente Blindenstöcke, kopfbasiertes Equipment und mobile Apps** erkennen Hindernisse und unterstützen gleichzeitig die Wegführung.
- **KI-gestützte Lösungen** (z. B. YOLO-basierte Erkennung und Echtzeit-Segmentierung) identifizieren komplexe Hindernisse wie Wände oder Türen mit hoher Präzision.
- **Einige Systeme** nutzen elektrotaktilen Feedback, z. B. durch Zungenstimulation, um die Navigation zu erleichtern [39].

3.1.1 Anwendung von Convolutional Neural Networks (CNNs) zur Positionsschätzung

CNNs sind zu einem leistungstarken Werkzeug für die Positionsschätzung geworden, insbesondere in Anwendungen, die eine präzise Objektlokalisierung und -verfolgung erfordern. Ihre Fähigkeit, räumliche Merkmale aus Bildern und Sensordaten zu extrahieren, macht sie in der Robotik, autonomen Navigation und industriellen Automatisierung hochwirksam. [32]

Die Positionsschätzung beinhaltet die Bestimmung der räumlichen Koordinaten oder der Orientierung von Objekten in Bildern oder Sensordaten. CNNs werden für diese Aufgabe aufgrund ihrer Fähigkeit, hierarchische Merkmale aus Rohdaten zu lernen, weit verbreitet eingesetzt. Nachfolgend finden Sie eine Aufschlüsselung, wie CNNs in diesem Bereich angewendet werden, zusammen mit Schlüsselarchitekturen und Herausforderungen. [38]

Wie CNNs die Positionsschätzung ermöglichen

CNNs verarbeiten visuelle und Sensordaten, um die Position eines Objekts zu schätzen, indem sie:

- **Merkmalextraktion:** Schlüsselmuster in Bildern oder Sensorinputs identifizieren.
- **Tiefen- & Raumwahrnehmung:** Mehrschichtige Architekturen zur Analyse von Objektabständen und -orientierungen nutzen.
- **Echtzeitanpassung:** Positionsschätzungen kontinuierlich auf der Grundlage von Umweltveränderungen verfeinern.

Anwendungen von CNNs in der Positionsschätzung

- **Robotik & Steuerung:** CNNs helfen selbstfahrenden Autos, Fahrspurpositionen, Hindernisse und Fußgänger zu erkennen. In der Robotik ermöglichen CNN-basierte Vision-Systeme eine präzise Objektmanipulation und Navigation. CNNs werden in der Robotik häufig für Lokalisierung und autonome Bewegung eingesetzt. Sie helfen bei der Schätzung der Position von Objekten für Roboterarme, was eine präzise Manipulation in der Industrieautomation und Gesundheitsrobotik ermöglicht.
- **Cybersicherheit:** CNNs können helfen, positionsbasiertes Verhalten in Cybersicherheitssystemen zu schätzen, indem sie Anomalien in der Netzwerkaktivität verfolgen und bösartige Zugangspunkte erkennen. Zum Beispiel analysieren Deep-Learning-Modelle Muster in Cyberangriffen, um deren Ursprung und Position innerhalb eines Systems zu bestimmen und so Intrusionen zu verhindern. Sie unterstützen die Lagerautomatisierung, indem sie Roboter an bestimmte Orte führen.
- **Medizinische Informationsverarbeitung:** CNNs verbessern die Positionsverfolgung in der Roboterchirurgie und gewährleisten Präzision. Sie helfen bei der MRT- und CT-Ausrichtung, verbessern die diagnostische

Genauigkeit, indem sie die Position von Anomalien in Röntgen-, MRT- und CT-Bildern bestimmen. Sie unterstützen die Roboterchirurgie, indem sie chirurgische Instrumente mit hoher Präzision verfolgen.

- **Natural Language Processing (NLP):** CNNs können bei der Positionsschätzung von Schlüsselwörtern oder -phrasen innerhalb großer Datensätze helfen. Zum Beispiel helfen CNNs, ortsbezogene Informationen aus Textdaten zu extrahieren, was Anwendungen wie die geospatialen Analysen für die Smart-City-Entwicklung verbessert.

3.1.2 Vorverarbeitungsschritte: Datensatzerstellung, Bildbeschriftung, Augmentierung

Die Vorverarbeitung ist eine kritische Phase bei der Entwicklung robuster Computer-Vision-Modelle, insbesondere für Aufgaben wie Bildklassifizierung, Objekterkennung oder Segmentierung. Dieser Abschnitt befasst sich mit drei wichtigen Vorverarbeitungsschritten: Datensatzerstellung, Bildbeschriftung und Datenaugmentation, die zusammen eine qualitativ hochwertige Eingabedaten für das Training von Deep-Learning-Modellen gewährleisten.

1. Datensatzerstellung Die Datensatzerstellung umfasst das Sammeln und Organisieren von Bildern, die für das Problemfeld relevant sind. Wichtige Überlegungen sind:

- **Datenquellen:**
 - Öffentliche Datensätze (z. B. ImageNet, COCO, CIFAR-10).
 - Benutzerdefinierte Datensätze (z. B. Web-Scraping, manuelle Sammlung oder synthetische Datengenerierung). [20]
- **Diversität und Repräsentativität:**
 - Sicherstellen, dass der Datensatz Variationen in Beleuchtung, Winkeln, Hintergründen und Objektskalen abdeckt, um Verzerrungen zu vermeiden.
 - Für die medizinische Bildgebung müssen Datensätze seltene Fälle enthalten, um die Generalisierbarkeit des Modells zu verbessern. [29]
- **Strukturierte Speicherung:**
 - Bilder in Ordnern organisieren (z. B. klassenweise für Klassifizierungsaufgaben).
 - Standardisierte Formate (JPEG, PNG) und Auflösungen (z. B. 256x256 für Konsistenz) verwenden. [20]

2. Bildbeschriftung

Die Beschriftung weist Bildern sinnvolle Anmerkungen zu und ermöglicht uns ein überwachtes Lernen. In einer 2022 veröffentlichten Studie hat ein Forscherteam ein schwach überwachtes Convolutional Neural Network (CNN) zur Objektklassifizierung entwickelt, das während des Trainings nur Labels auf Bildebene (die das Vorhandensein oder Fehlen eines Objekts angeben) verwendet und dennoch in der Lage ist, aus überladenen Szenen mit mehreren Objekten zu lernen. Die Leistung des Modells wird an zwei Benchmark-Datensätzen bewertet: Pascal VOC 2012 (20 Objektklassen) und dem deutlich größeren Microsoft COCO (80 Objektklassen). Die Analyse zeigt, dass das Netzwerk Folgendes konnte:

- Erreicht hohe Genauigkeit bei der Vorhersage von Labels auf Bildebene.
- Lokalisiert Objekte ungefähr (aber nicht deren präzise Ausdehnung).
- Erreicht eine Leistung, die mit vollständig überwachten Gegenständen vergleichbar ist, die mit Bounding-Box-Annotationen trainiert wurden.

Bemerkenswert ist, dass das Netzwerk lernt, Objekte ohne jegliche räumliche Überwachung (z. B. Bounding Boxes oder Segmentierungsmasken) während des Trainings zu lokalisieren, indem es sich ausschließlich auf binäre Objekt-Präsenz-Labels stützt. Darüber hinaus werden Objekte mit typischerem Aussehen (z. B. Motorräder, wie in der linken Spalte gezeigt) im Trainingsprozess früher lokalisiert als solche mit größerer Variabilität innerhalb der Klasse. [35]




Abb 3.1 Links: MNIST-Ziffernbeispiele. Mitte-links: Drei Faltungskerne (tatsächliche Größe und vergrößert; mittelgrau=0, hell=positiv, dunkel=negativ). Mitte-rechts: Kernreaktionen auf Ziffern angewendet. Rechts: Schwellenwerte der Aktivierungen (grün=positiv, rot=negativ). Die Kerne fungieren als (von oben nach unten): ein

horizontaler Balkendetektor, ein vertikaler Balkendetektor und ein Linienendendetektor, empfindlich gegenüber der Kontrastpolarität. Obwohl effektiv, bleibt ihre Lokalisierung unvollkommen. Aus S. Russell und P. Norvig, Artificial Intelligence: A Modern Approach, 4th ed., 2021. [19]

CNNs zeichnen sich bei der Bildklassifizierung durch ihre Fähigkeit aus, hierarchische Merkmalsdarstellungen direkt aus Pixeldaten zu lernen. Um zu verstehen, warum CNNs gut funktionieren, ist es lehrreich, Bilddatensätze wie MNIST zu untersuchen, einen Standard-Benchmark, der aus 70.000 handgeschriebenen Ziffern (0–9) besteht. Die Analyse dieses Datensatzes zeigt zwei Schlüsseleigenschaften von Bildern:

1. **Invarianz gegenüber lokalen Störungen:** Kleine Transformationen (z. B. Translation, Rotation, Helligkeitsänderungen) verändern die semantische Bedeutung eines Bildes nicht. Zum Beispiel bleibt eine Ziffer "8" erkennbar, auch wenn sie leicht verschoben wird, was impliziert, dass genaue Pixelpositionen weniger kritisch sind als strukturelle Muster.
2. **Lokale und hierarchische Merkmalsbedeutung:** Diskriminierende Merkmale ergeben sich oft aus lokalisierten Mustern und ihren räumlichen Beziehungen.

Praktische Verbesserungen und Herausforderungen Obwohl CNNs ohne umfangreiche Abstimmung eine starke Leistung erzielen können, verbessern verschiedene Techniken die Robustheit weiter:

- **Datenaugmentation:** Die künstliche Erweiterung des Trainingsdatensatzes mit gestörten Kopien reduziert Overfitting und verbessert die Generalisierung. Testzeit-Augmentierung kann auch die Vorhersagestabilität verbessern.
- **Kontextuelles Lernen:** CNNs lernen implizit, diskriminierende Regionen zu priorisieren, selbst wenn Objekte nur einen Bruchteil der Pixel einnehmen. Kontextuelle Hinweise können die Erkennung unterstützen, obwohl ihr Nutzen von den Datenspezifika abhängt.[19]

3. Datenaugmentation

Datenaugmentation erweitert den Datensatz künstlich durch Anwenden von Transformationen auf vorhandene Bilder, wodurch die Modellrobustheit verbessert und Overfitting reduziert wird. Techniken umfassen:

A. Grundlegende Augmentierungen

- **Geometrische Transformationen:**
 - Rotation: Bilder um 10° – 30° drehen.
 - Spiegelung: Horizontale/vertikale Spiegelungen.
 - Zuschneiden/Translation: Zufällige Ausschnitte oder Verschiebungen.
- **Photometrische Transformationen:**

- Helligkeit/Kontrast: Beleuchtungsbedingungen anpassen.
- Farbjittering: RGB-Kanäle stören.
- Rauschinjektion: Gaußsches Rauschen hinzufügen, um Sensorartefakte zu simulieren.

B. Fortgeschrittene Augmentierungen

- **Zufälliges Löschen (Random Erasing):** Zufällige Bereiche maskieren, um den Fokus auf ganze Objekte zu erzwingen.
- **Mixup:** Zwei Bilder linear mischen.
- **GAN-basierte Augmentierung:**
 - Generieren synthetischer Bilder.
 - Stiltransfer.
- **Meta-Learning Augmentierungen:**
 - Verwenden von Reinforcement Learning, um optimale Augmentierungsstrategien zu entdecken.

Datenaugmentation im maschinellen Lernen Die synthetische Generierung von gelabelten Daten deutet darauf hin, dass dies durch die Nutzung inhärenter statistischer Symmetrien in den Daten geschieht. Viele Anwendungen des maschinellen Lernens umfassen Datensätze, die, zumindest annähernd, intrinsische Symmetrien und Invarianzen aufweisen. Zum Beispiel bleibt ein gedrehtes Bild einer handgeschriebenen Zahl als diese Zahl erkennbar, und eine an einem bestimmten Ort aufgenommene Temperaturmessung wird einer nur wenige Augenblicke später vorgenommenen Messung sehr ähnlich sein. Datenaugmentation nutzt solche Symmetrien und Invarianzen, um Rohdatensätze durch die Einführung zusätzlicher synthetischer Daten zu erweitern. [41]

Gegeben sei ein Rohdatensatz: $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$

Der entsprechende augmentierte Datensatz wird bezeichnet als:

$$D_0 = \{(x_{\{11\}}, y_1), (x_{\{12\}}, y_1), \dots, (x_{\{mB\}}, y_m)\}$$

Wobei $m_0 = B \times m$ die Gesamtgröße des augmentierten Datensatzes darstellt.

Und wenn empirische Risikominimierungs (ERM)-Methoden verwendet werden, tritt häufig Overfitting auf, wenn die Dimensionalität des Hypothesenraums die Anzahl der Trainingsbeispiele übersteigt. Regularisierung und Modellauswahl mildern dieses Problem, indem sie den Hypothesenraum einschränken. Ein alternativer Ansatz ist die Datenaugmentation, bei der der Trainingsdatensatz synthetisch erweitert wird, indem inhärente Datensymmetrien genutzt werden – zum Beispiel bleibt ein gedrehtes Bild einer Katze eine gültige Darstellung einer Katze. [36]

Datenaugmentation dient als implizite Regularisierungstechnik, wobei die Störverteilung $p(\epsilon)$ den Regularisierungseffekt bestimmt. Dieser Ansatz ermöglicht es, den Bias-

Varianz-Kompromiss ohne explizite Strafterme auszugleichen, was ihn besonders in Szenarien mit wenig Daten wertvoll macht. [26]

3.1.3 Modelle für die Koordinatenregression

Die Koordinatenregression beinhaltet die Vorhersage kontinuierlicher numerischer Werte (Koordinaten) aus Eingabedaten. Die Koordinatenregression ist also der Prozess der Vorhersage präziser räumlicher Koordinaten aus einer gegebenen Eingabe, anstatt Objekte in Kategorien zu klassifizieren. Bei Computer-Vision-Aufgaben ist die Koordinatenregression für Anwendungen wie menschliche Haltungsschätzung, Objekterkennung und -verfolgung unerlässlich. Traditionelle CNN-Architekturen verlassen sich oft auf Heatmap-basierte Methoden für räumliche Aufgaben, aber DSNT führt einen direkteren Ansatz für die Koordinatenregression ein, während räumliche Generalisierbarkeit und End-to-End-Differenzierbarkeit erhalten bleiben. [37]

Problemdefinition Die Haltungsschätzung für mehrere Personen zielt darauf ab, anatomische Schlüsselpunkte für alle Personen in einem Bild zu identifizieren. Jede Haltung wird durch K 2D-Schlüsselpunkte dargestellt.

Entkoppelte Schlüsselpunktregression (DEKR) Das DEKR-Framework sagt Haltungskandidaten an jedem zentralen Pixel q voraus, indem es einen $2K$ -dimensionalen Offsetvektor o_q schätzt, der q auf die K Schlüsselpunkte abbildet. Offset-Karten O werden über eine Regressionsfunktion F generiert: $O=F(X)$, wobei X Backbone-Merkmale darstellt (HRNet in dieser Studie).




Abb 3.2 Diese Abbildung veranschaulicht den DEKR-Prozess, bei dem jeder Schlüsselpunkt separat über einen dedizierten Zweig gelernt wird. Jeder Zweig extrahiert Merkmale mithilfe von zwei adaptiven Faltungen und sagt dann den 2D-Offset für seinen entsprechenden Schlüsselpunkt mithilfe einer 1×1 -Faltung voraus. Basierend auf der Studie *Bottom-Up Human Pose Estimation Via Disentangled Keypoint Regression* (2021). [46]

Schlüsselinnovationen

- **Adaptive Faltungen:** Im Gegensatz zu Standardfaltungen passen adaptive Faltungen die rezeptiven Felder dynamisch an, um sich auf Schlüsselpunktregionen zu konzentrieren. Für ein zentrales Pixel q wird die Aktivierung $y(q)$ berechnet als: $(q) = \sum Wix(q + g_{\{s_i\}}^q)$, wobei $g_{\{s_i\}}^q$ gelernte Offsets sind, die aus einer affinen Transformation Aq und Translation t abgeleitet werden, was eine pixelweise räumliche Anpassung ermöglicht.
- **Mehrzweig-Regression:** DEKR verwendet K parallele Zweige, von denen jeder eine dedizierte Merkmalskarte X_k verarbeitet, um Offsets für den k -ten Schlüsselpunkt vorherzusagen: $O_k = F_k(X_k)$, für $k=1, \dots, K$. Dies entkoppelt das Merkmalenlernen und verbessert die Lokalisierungsgenauigkeit. [46]

Verlustfunktionen

- **Regressionsverlust:** Der Smooth L1-Verlust bestraft Offset-Fehler, normalisiert durch die Instanzgröße Z_i : $\ell_p = \sum \left(\frac{1}{Z_i}\right) \text{smoot}\{L_1\}(o_i - o_k)$
- **Heatmap-Verlust:** Ein separater Zweig sagt Schlüsselpunkt-Heatmaps H und Zentrum-Heatmaps C voraus, die mittels maskiertem L2-Verlust überwacht werden $\ell_h = \|M_h \odot (H - H^*)\|^2 + \|M_c \odot (C - C^*)\|^2$. Hier gewichten M_h und M_c Nicht-Schlüsselpunktregionen herunter.
- **Gesamtverlust:** $\ell = \ell_h + \lambda \ell_p$, wobei $\lambda=0.03$. [51]

Vorteile

- **Präzision:** Die Mehrzweig-Regression minimiert Interferenzen zwischen Schlüsselpunkten.
- **Flexibilität:** Adaptive Faltungen verbessern den Fokus auf Schlüsselpunktregionen. [46]

3.1.4 Robustheitsüberlegungen: Beleuchtung, Verdeckung, Echtzeit-Feedback

In einer Studie über CNN-Varianten untersuchten Forscher Beleuchtungsüberlegungen und betonten die Bedeutung der Beleuchtung in maschinellen Visionssystemen. Sie hoben hervor, dass "Beleuchtung das zu inspizierende Teil so beleuchtet, dass seine Merkmale hervorstechen und von der Kamera präzise gesehen werden können", und diskutierten verschiedene Beleuchtungsaufbauten wie Front- und Hintergrundbeleuchtung zur Verbesserung der Objektsichtbarkeit. [38] Verschiedene Lichtquellen, darunter Glühlampen, Leuchtstofflampen, Laser, Röntgenröhren und Infrarotlichter, wurden als wesentlich für die Verbesserung der Bildqualität bei der industriellen Inspektion genannt. [44]

Die Herausforderungen, denen Gesichtserkennungssysteme gegenüberstehen, betonen die Notwendigkeit, Variationen in der Beleuchtung, Haltungsänderungen und Gesichtsausdrücke zu berücksichtigen. Diese Faktoren beeinflussen die Modellleistung

erheblich und erfordern fortschrittliche Techniken wie tiefe Convolutional Neural Networks, um die Robustheit zu verbessern. Studien haben Methoden wie Multitasking-kaskadierte CNNs und adaptive Vorverarbeitung vorgeschlagen, um die Erkennungsgenauigkeit unter verschiedenen Bedingungen zu verbessern. [46]

Zur Handhabung von Verdeckungen diskutierte die Studie Deep Learning (DL) und Convolutional Neural Networks (CNNs) als kritische Werkzeuge in modernen Computer-Vision-Techniken. Obwohl Verdeckungsprobleme nicht explizit detailliert wurden, verwies die Forschung auf fortgeschrittene KI-Modelle, die visuelle Daten unter verschiedenen Bedingungen verarbeiten und eine zuverlässige Bilderkennung ermöglichen, selbst wenn bestimmte Merkmale teilweise verdeckt sind. [44]

In einer anderen Studie untersuchten Forscher die Verdeckungsbehandlung in Haltungsschätzungsmodellen. Sie stellten fest, dass "die Behandlung des Verdeckungsproblems" eine kritische Herausforderung bei der Haltungsschätzung mehrerer Personen ist und verwiesen auf mehrere Ansätze zur Verbesserung der Leistung unter Bedingungen teilweiser Sichtbarkeit. Die Studie diskutierte Methoden wie Verbesserungen der Schlüsselpunktolokalisierung, Multi-Task-Lernarchitekturen und Gruppierungstechniken zur Assoziation von Schlüsselpunkten, die zu derselben Person gehören, was dazu beiträgt, die Auswirkungen der Verdeckung zu mindern. [46]

Hinsichtlich des Echtzeit-Feedbacks untersuchte die Studie die Rolle von Machine Vision (MV)-Systemen, d.h. Systemen, die KI-gesteuerte Bildverarbeitung für die Echtzeit-Visualisierung verwenden, um eine sofortige und automatisierte Inspektion in Hochgeschwindigkeits-Produktionslinien zu gewährleisten. Es wurde festgestellt, dass "MV sich bei der quantitativen Messung einer strukturierten Szene aufgrund ihrer Geschwindigkeit, Genauigkeit und Wiederholbarkeit auszeichnet", was eine effiziente Qualitätskontrolle in Fertigungsanwendungen ermöglicht. [44]

3.1.5 Beispielarchitekturen

Convolutional Neural Networks (CNNs) sind ein entscheidendes KI-Werkzeug für Computer Vision (CV)-Aufgaben, die sich durch Objekterkennung, Klassifizierung und Segmentierung auszeichnen. Ihr Erfolg hängt von großen gelabelten Datensätzen ab, was sie in Anwendungen wie der Verkehrszeichenerkennung, medizinischen Bildgebung, Gesichtserkennung und Objekterkennung hochwirksam macht.

Schlüsselanwendungen in Computer Vision

- **Gesichtserkennung:** CNNs bewältigen Herausforderungen wie Beleuchtungsvariationen und Verdeckungen. Methoden wie tiefe CNNs (Farfadi et al., 2015) und Multitask-kaskadierte CNNs (Zhang et al., 2016) haben die Genauigkeit verbessert.

- **Menschliche Haltungsschätzung:** CNN-Architekturen verfeinern Körper-Heatmaps mittels Regressionstechniken (Bulat & Tzimiropoulos, 2016).
- **Aktionserkennung:** Traditionell auf Bewegungsbilder und HMMs angewiesen, übertreffen 3D-CNNs in Kombination mit LSTMs (Wang et al., 2017) nun frühere Ansätze. [60]

Breitere KI-Anwendungen CNNs erstrecken sich über Computer Vision hinaus in die Bereiche der natürlichen Sprachverarbeitung, Objekterkennung, Spracherkennung, Videoanalyse und mehrdimensionale Dateninterpretation, was ihre Vielseitigkeit in der modernen KI-Forschung demonstriert.

Ein Beispiel für eine Architektur ist YOLO (You Only Look Once), ein weit verbreitetes Objekterkennungsframework, das Bounding Boxes vorhersagt und Objekte in vordefinierte Kategorien klassifiziert. YOLO ist ein Echtzeit-Objekterkennungsmodell, das auf CNNs basiert. Es verarbeitet ein gesamtes Bild auf einmal und identifiziert mehrere Objekte effizient. Standard-YOLO fehlt jedoch die Fähigkeit, Objektabstände von der Kamera zu schätzen. Um diese Einschränkung zu beheben, hat ein Forscherteam Dist-YOLO verwendet, eine verbesserte Version, die die Abstandsschätzung integriert, während die ursprünglichen YOLO-Erkennungsfähigkeiten beibehalten werden. [35]




Abb 3.3 Die YOLO-Architektur wird modifiziert, um die Entfernung von Objekten zu schätzen, basierend auf der Studie *Dist-YOLO: Fast Object Detection with Distance Estimation* (M, 2022). [35]

Der Ansatz erweitert die von den YOLO-Erkennungsköpfen generierten Vorhersagevektoren um Entfernungsinformationen und integriert eine spezielle Entfernungsverlustfunktion während des Trainings. Experimentelle Ergebnisse zeigen, dass Dist-YOLO nicht nur die ursprüngliche Kapazität des Backbone-Netzwerks beibehält, sondern auch die Genauigkeit der Bounding-Box-Erkennung im Vergleich zum YOLO-Basismodell verbessert. Darüber hinaus bietet Dist-YOLO in Verbindung mit einer monokularen Kamera eine präzise Abstandsschätzung für erkannte Objekte, was seine Anwendbarkeit in realen Szenarien erheblich erweitert. [35]

Im Gegensatz zu herkömmlichen zweistufigen Detektoren wie R-CNN formuliert YOLO die Objekterkennung als einstufiges Regressionsproblem um, so dass das Modell die

Bounding Boxes und Klassenwahrscheinlichkeiten direkt aus einem Bild in einem Durchgang vorhersagen kann. Diese Designentscheidung führt zu extrem schnellen Schlussfolgerungen, was es ideal für zeitkritische Anwendungen wie Videoüberwachung, autonomes Fahren und Robotik macht. [47]




Abb. 3.4 Netzwerkarchitektur von YOLOv4.basierend auf der Studie Anwendung von verschiedenen YOLO Models for Computer Vision-Based Real-Time Pothole Detection (2021). [47]

Key Improvements Across YOLO Versions

- **YOLOv1-v3**: Introduced multi-scale **feature pyramids (FPN)**, an optimized **Darknet53 backbone**, and binary cross-entropy loss for classification.
- **YOLOv4**: Enhanced the framework with a **three-component structure** (backbone, neck, head) and advanced **optimization techniques** ("bag of freebies"). Achieved high accuracy (43.5% AP on MS COCO) with real-time performance (65 FPS on Tesla V100).
- **YOLOv4-tiny**: A lightweight version using **CSPDarknet53-tiny**, optimized for low-resource environments.
- **YOLOv5**: Improved **network efficiency**, **streamlined architecture**, and **PyTorch-based implementation**. It retained YOLOv4's accuracy while enhancing deployment with YOLOv5 offering enhanced accuracy and speed. [28]

Eine andere Studie konzentrierte sich auf die Annäherung nichtlinearer Funktionen mit Hilfe fortschrittlicher neuronaler Architekturen, insbesondere residualer neuronaler Netze (ResNet), die für nichtlineare Regression und nicht für bildbasierte Aufgaben angepasst

wurden. Der methodische Kern passt die ResNet-Prinzipien an die nichtlineare Regression an, indem er Faltungsschichten durch vollständig verbundene Blöcke ersetzt (Abb 2). Diese Anpassung geht auf die Dimensionsbeschränkungen traditioneller ResNet-Architekturen bei der Verarbeitung von Vektoreingaben anstelle von Bilddaten ein. [61]

Einige der wichtigsten Änderungen sind:

1. **Architektonische Anpassung:** Umwandlung von Restblöcken in dichte Schichten unter Beibehaltung der Stapelnormalisierung zur Regularisierung.
2. **Dimensionale Handhabung:** Identitätsblöcke (Tafel a) für dimensionserhaltende Flüsse und dichte Blöcke (Tafel b) für dimensionsverschiebende Operationen.
3. **Rechnerische Optimierung:** Eliminierung lokaler Faltungsoperatoren zugunsten globaler dichter Verbindungen. [62]

Die empirische Validierung nutzt synthetisch generierte Datensätze (Gleichungen 2–5) mit **10^7 Stichproben pro Funktionsklasse**, aufgeteilt in:

- Trainingsdaten: $6,75 \times 10^6$
- Validierungsdaten: $7,5 \times 10^5$
- Testdaten: $2,5 \times 10^6$

Die optimale Konfiguration mit 28 Schichten und einer Breite von 16 erreicht eine außergewöhnliche Leistung (Testverluste zwischen $2,55 \times 10^{-5}$ und $4,21 \times 10^{-4}$) und übertrifft deutlich:

- **Lineare Methoden** ($R^2 < 0,5$ in allen Fällen)
- **Klassische nichtlineare Ansätze** (z. B. SVR mit Trainingszeiten > 12 Stunden)
- **Standard-Neuronale Netze** (20–30 % höhere Validierungsverluste)

Wie in **Tabelle 5** quantifiziert, zeigen visuelle Vergleiche (**Abbildung 5**) eine präzise Übereinstimmung zwischen Vorhersagen und Grundwahrheit über verschiedene Funktionskomplexitäten hinweg [62].

3.1.6 Signale zur Anomalieerkennung

Im Zeitalter des Internet der Dinge (IoT) und der zunehmenden Komplexität von Netzwerken ist die Anomalieerkennung für die Gewährleistung der Datensicherheit und der Zuverlässigkeit von Systemen von entscheidender Bedeutung. Künstliche Intelligenz spielt eine zentrale Rolle bei der Identifizierung ungewöhnlicher Muster, die auf Bedrohungen, Fehler oder Fehlfunktionen hinweisen könnten. Dieser Abschnitt befasst sich mit der Anwendung von KI in der Anomalieerkennung und hebt bestimmte Herausforderungen und Ansätze hervor.

3.1.6.1 Herausforderungen in der KI-basierten Anomalieerkennung

Trotz der Fortschritte bei KI-basierten Methoden zur Anomalieerkennung bleiben erhebliche Herausforderungen bestehen, insbesondere in komplexen Systemen wie drahtlosen Sensornetzwerken (WSNs) und heterogenen Datensätzen.

- **Hohe Dimension und Datenvolumen:** Moderne Netzwerke generieren riesige Datenmengen mit vielen Merkmalen, was das Training von Anomalieerkennungsmodellen rechenintensiv und speicherintensiv macht.
- **Mangel an gelabelten Anomaliendaten:** Echte Anomalien sind selten und schwer zu labeln, was überwachte Lernansätze behindert. Dies erfordert den Einsatz von unüberwachten oder semi-überwachten Methoden.
- **Konzeptdrift:** Das Verhalten von Anomalien kann sich im Laufe der Zeit ändern, was dazu führt, dass trainierte Modelle veraltet werden und eine kontinuierliche Anpassung erfordern.
- **Rauschen und irrelevanten Merkmalen:** Daten enthalten oft Rauschen und irrelevante Merkmale, die die Leistung von Anomalieerkennungsalgorithmen mindern.
- **Rechenbeschränkungen am Edge:** In WSNs und IoT-Geräten mit begrenzten Rechenressourcen ist es schwierig, komplexe Anomalieerkennungsalgorithmen direkt am Sensor (Edge Processing) zu implementieren.

Eine 2023 veröffentlichte Studie, die verschiedene Methoden zur Anomalieerkennung in WSNs vergleicht, beleuchtet diese Herausforderungen. Die Forscher kamen zu dem Schluss, dass die Neubewertung bestehender Modelle entscheidend ist, da veröffentlichte Ergebnisse oft aufgrund inkonsistenter Bewertungsmetriken oder Datensätze variieren. Sie fanden heraus, dass einfache Modelle wie Vanilla-Autoencoder (DAE) komplexere Architekturen übertreffen können, wenn sie auf herausfordernden Datensätzen wie CSE-CIC-IDS2018 trainiert werden, die aussagekräftigere Einblicke bieten als weit verbreitete, aber triviale Datensätze wie KDD. Darüber hinaus betonen sie die Notwendigkeit robuster Modelle zur Anomalieerkennung in WSNs angesichts von Bedrohungen wie Hardwarefehlern, Umweltveränderungen oder Cyberangriffen. [60]

3.1.6.2 KI-basierte Anomalieerkennung in drahtlosen Sensornetzwerken (WSNs)

Drahtlose Sensornetzwerke (WSNs) spielen eine entscheidende Rolle im Internet der Dinge (IoT), aber Sensoranomalien – verursacht durch Hardwarefehler, Umweltveränderungen oder Cyberangriffe – bedrohen die Datenzuverlässigkeit. Traditionelle zentralisierte Anomalieerkennung ist aufgrund hoher Datenübertragungskosten ineffizient, während verteilte Methoden oft unter hoher Rechenkomplexität oder übermäßiger Kommunikation zwischen Sensoren leiden.

Autoencoder-basierte Anomalieerkennung für WSNs Ein dreischichtiger Autoencoder komprimiert und rekonstruiert Sensordaten, um Anomalien auf der Grundlage von Rekonstruktionsfehlern zu erkennen, wobei er ohne gelabelte Daten durch unüberwachtes Lernen arbeitet. [62]

Verteilter Algorithmus-Ansatz

- **Sensor-Ebene (Edge Processing):** Jeder Sensor erkennt Anomalien lokal durch Vergleich von Eingabe- und rekonstruierten Werten, was keine Kommunikation zwischen Sensoren erfordert.
- **Cloud-Ebene-Verarbeitung:** Aggregiert Residuen und aktualisiert globale Statistiken, wobei der Autoencoder regelmäßig neu trainiert wird, um die Genauigkeit zu erhalten und gleichzeitig den Sensor-Overhead zu reduzieren.

Vergleich verschiedener Ansätze zur Anomalieerkennung. [41]

3.2 Algorithmen zur Kantenerkennung und KI-Verbesserungen: Ein umfassender Überblick

Die Kantenerkennung ist eine grundlegende Technik der Bildverarbeitung und des maschinellen Sehens und spielt eine entscheidende Rolle in einer Vielzahl von Anwendungen und Disziplinen. Sie dient häufig als ein kritischer Vorverarbeitungsschritt bei der Bildsegmentierung, indem sie hilft, Bilder in sinnvolle Bereiche zu unterteilen, indem Objektgrenzen und -strukturen klar abgegrenzt werden. In der Objekterkennung und -klassifikation definiert die Kantenerkennung die Konturen von Objekten, was eine präzise Klassifizierung und weiterführende Analyse unterstützt. Besonders wichtig ist sie in der Robotik und in autonomen Systemen, da sie die visuelle Echtzeitverarbeitung für Hinderniserkennung, Navigation und Umweltinterpretation ermöglicht. In der Biometrie verbessert die Kantenerkennung die Erkennung komplexer Muster wie Fingerabdrücke und Netzhautscans und erhöht so die Genauigkeit der Identifikation. Auch bei der Dokumentenanalyse spielt sie eine Rolle, indem sie die Zeichenerkennung, Formularverarbeitung und Textextraktion erleichtert. Darüber hinaus unterstützt die Kantenerkennung bei der Verarbeitung von Satellitenbildern die Bewertung von Landschaftsformen, die Überwachung städtischer Entwicklungen und die Umweltanalyse. Diese vielfältigen Anwendungen unterstreichen die unverzichtbare Rolle der Kantenerkennung bei der Gewinnung kritischer visueller Informationen und bilden die Grundlage für fortschrittliche Bildanalysetechniken in zahlreichen Bereichen. [81]

Die Fähigkeit, Kanten in einem Bild präzise zu identifizieren und zu extrahieren, hat direkten Einfluss auf die Leistungsfähigkeit nachgelagerter Anwendungen. Im Laufe der Jahrzehnte haben sich die Methoden der Kantenerkennung erheblich weiterentwickelt – von einfachen gradientenbasierten Operatoren bis hin zu hochentwickelten Deep-Learning-Modellen. Dieser Abschnitt bietet eine eingehende Untersuchung klassischer Kantenerkennungsalgorithmen, ihrer Anwendungen in präzisen Messtechnologien, ihrer inhärenten Einschränkungen sowie der Art und Weise, wie künstliche Intelligenz dieses Feld durch fortgeschrittene Modelle und hybride Ansätze revolutioniert hat.

Mit dem wachsenden Bedarf an hochpräziser und hocheffizienter Messtechnik in der Fertigung mechanischer Komponenten gewinnen robuste und genaue

Kantenerkennungsalgorithmen zunehmend an Bedeutung. In dieser Studie wird eine neuartige Kantenerkennungsmethode auf Subpixel-Niveau basierend auf dem gaußschen Integrationsmodell vorgeschlagen, um diesem Bedarf gerecht zu werden. [82]

Die Kantenerkennung bleibt ein Eckpfeiler des maschinellen Sehens und der Bildverarbeitung und spielt eine zentrale Rolle bei der Extraktion bedeutungsvoller struktureller Informationen aus digitalen Bildern. Durch die Identifikation signifikanter Intensitätsänderungen ermöglicht die Kantenerkennung die Abgrenzung von Objektgrenzen und unterstützt dadurch zentrale Aufgaben wie Objekterkennung, Bildsegmentierung und Merkmalsextraktion. [81]

Im Laufe der Jahrzehnte wurden zahlreiche Methoden zur Kantenerkennung vorgeschlagen, die sowohl grundlegende Beiträge als auch aktuelle Fortschritte widerspiegeln. Zu den frühesten Techniken zählt der Kantenerkennungsalgorithmus basierend auf dem Roberts-Operator, der 1963 von Lawrence Roberts eingeführt wurde und einen Meilenstein in der Entwicklung des maschinellen Sehens darstellt. [81]

Arten von Kanten bei der Kantenerkennung

Das Verständnis dieser Kantentypen ist entscheidend, da sie wichtige Hinweise über die Objekte, Materialien und Lichtverhältnisse in einem Bild liefern. Die Erkennung des spezifischen Kantentyps verbessert die Genauigkeit der Interpretation und unterstützt die Entwicklung von Kantenerkennungstechniken, die auf unterschiedliche Kantenmerkmale abgestimmt sind.

Kanten in Bildern weisen je nach Intensitäts- oder Farbänderung zwischen benachbarten Pixeln unterschiedliche Eigenschaften auf. Diese Unterschiede ermöglichen eine Klassifizierung der Kanten in mehrere unterschiedliche Typen, wie in Abbildung 3.5 dargestellt. Jeder Typ vermittelt einzigartige Informationen über die Struktur und den Inhalt des Bildes. [82]

Arten von Rändern in Bildern:

Stufenkanten (Step)

Stufenkanten sind die grundlegendste und am häufigsten vorkommende Art von Kanten. Sie zeichnen sich durch einen abrupten und signifikanten Intensitätswechsel zwischen benachbarten Pixeln aus. Diese scharfen Übergänge entsprechen typischerweise Objektgrenzen oder plötzlichen Änderungen in der Oberflächenausrichtung, bei denen die Pixelwerte schnell von einem Helligkeits- oder Farbniveau zu einem anderen springen. [85]

Rampenkanten (Ramp)

Rampenkanten beschreiben einen allmählicheren Intensitätswechsel, der häufig einer gleichmäßigen, linearen Übergangsform über die Pixel hinweg ähnelt. Solche Kanten

entstehen oft durch graduelle Beleuchtungsänderungen oder Materialübergänge, wie etwa beim sanften Wechsel von Schatten- zu beleuchteten Bereichen. [85]

Gratkanten (Ridge)

Gratkanten treten auf, wenn die Intensität zunächst allmählich abnimmt und anschließend stark ansteigt, wodurch ein gratartiges Profil im Bild entsteht. Diese Kanten sind häufig dort zu beobachten, wo helle Bereiche in Schattenzonen übergehen und so ein charakteristisches Intensitätsmuster erzeugen. [85]

Firstkanten (Roof)

Firstkanten zeigen eine allmähliche Zunahme der Intensität, gefolgt von einem abrupten Abfall. Sie treten häufig in Bereichen mit Reflexionen oder Übergängen von Schatten zu hellen Lichtreflexen auf. [85]




Abb 3.5: *Types of edges. From Digital Image Processing – Latest Advances and Applications [85]*

3.2.1 Klassische Kantenerkennungsalgorithmen

Klassische Kantenerkennungsalgorithmen basieren hauptsächlich auf mathematischen Operationen zur Identifikation von Bildbereichen, in denen sich die Pixelintensitäten abrupt verändern. Solche Veränderungen entsprechen typischerweise den Grenzen von Objekten oder markanten Merkmalen innerhalb einer Szene. Die klassischen Ansätze lassen sich grob in Methoden erster und zweiter Ordnung unterteilen, die jeweils spezifische Vor- und Nachteile aufweisen. [88]

Die Kantenerkennung bleibt eine der grundlegendsten Aufgaben des maschinellen Sehens mit breit gefächerten Anwendungen, darunter Bildsegmentierung, Objekterkennung und Videoobjektsegmentierung. Ziel ist es, visuell auffällige Kanten und Objektgrenzen innerhalb eines Bildes präzise zu identifizieren. Trotz ihrer langen Geschichte stellt die Kantenerkennung weiterhin eine große Herausforderung dar – bedingt durch Faktoren wie komplexe Hintergrundszenen, Variationen im Erscheinungsbild von Objekten und Inkonsistenzen in von Menschen annotierten Ground-Truth-Daten. [88]

Klassische Kantenerkennungsalgorithmen haben das grundlegende Fundament für die moderne Computer Vision gelegt, indem sie die Extraktion von Objektgrenzen und Konturen aus digitalen Bildern ermöglichten. Zu den frühesten Methoden zählt der

Roberts-Operator, der 1963 von Lawrence Roberts eingeführt wurde und einen richtungsweisenden, wenn auch rudimentären Schritt in der Kantenerkennung darstellte, indem er einfache Gradientenabschätzungen nutzte. Aufbauend darauf wurde später der Prewitt-Operator entwickelt, um besser mit verrauschten Bildern und schwachen Pixelintensitäten umzugehen und somit in kontrastarmen Umgebungen eine verbesserte Leistung zu erzielen. Der Sobel-Operator, eine populäre Weiterentwicklung von Prewitt, führte gewichtete Faltungskerne ein, die stärkere Kantenreaktionen und eine bessere Rauschunterdrückung ermöglichten und dadurch breite Anwendung fanden. Weitere Fortschritte wurden durch den Einsatz des Laplace-Operators erzielt, der auf Ableitungen zweiter Ordnung basierte, um insbesondere in Bereichen mit raschen Intensitätsänderungen eine verbesserte Kantenlokalisierung zu ermöglichen. Ein bedeutender Meilenstein war die Einführung des Canny-Kantendetektors, der die Kantenerkennung durch die Kombination von gaußscher Glättung, Gradientenanalyse, Nicht-Maximum-Unterdrückung und Hysterese-Schwellenwertsetzung in einem umfassenden, mehrstufigen Algorithmus revolutionierte. Canny setzte neue Maßstäbe in Bezug auf Präzision, Rauschrobustheit und Kantenkontinuität und zählt bis heute zu den einflussreichsten Verfahren des Fachgebiets. Diese klassischen Algorithmen, auch wenn sie inzwischen als traditionell gelten, dienen aufgrund ihrer Einfachheit, Effizienz und Interpretierbarkeit weiterhin als Referenzmethoden und Vorverarbeitungsschritte in zahlreichen Anwendungen der Computer Vision. [89]

3.2.1.1 Sobel Operator

Der Sobel-Operator verwendet ein Paar von 3x3-Faltungskernen, um für jedes Pixel die Gradientenstärke und -richtung in einem Bild zu berechnen. Die Gradientenstärke gibt die Intensität der Kante an, während die Gradientenrichtung die Ausrichtung der Kante beschreibt. Der Sobel-Operator ist eine der am weitesten verbreiteten Kantenerkennungstechniken erster Ordnung. Er arbeitet, indem das Bild mit zwei kleinen, separierbaren, ganzzahligen Filtern in horizontaler und vertikaler Richtung gefaltet wird. Diese Filter sind so konzipiert, dass sie den Gradienten der Bildintensitätsfunktion annähern. Der horizontale Kernel betont dabei Kanten in vertikaler Richtung, während der vertikale Kernel horizontale Kanten hervorhebt. Die Gradientenstärke wird anschließend durch Kombination der Ausgaben beider Kerne berechnet, und Kanten werden dort erkannt, wo diese Stärke einen bestimmten Schwellenwert überschreitet. [84]

Eine der zentralen Stärken des Sobel-Operators ist seine rechnerische Effizienz, wodurch er sich gut für Echtzeitanwendungen eignet. Darüber hinaus sorgt die Integration einer gaußschen Glättung innerhalb der Kerne für eine gewisse Rauschunempfindlichkeit. Allerdings erzeugt der Sobel-Operator tendenziell relativ breite Kanten, was problematisch für Anwendungen sein kann, die eine hohe Präzision erfordern. Zudem nimmt seine Leistungsfähigkeit bei starkem Rauschen oder komplexen Texturen deutlich ab, da ihm die Fähigkeit fehlt, höherstufige semantische Informationen zu berücksichtigen. [87]

3.2.1.2 Laplacian of Gaussian (LoG)

Der Laplacian of Gaussian (LoG) ist eine Kantenerkennungsmethode zweiter Ordnung, die einige der Einschränkungen von Verfahren erster Ordnung adressiert. Der LoG-Operator wendet zunächst eine gaußsche Unschärfe auf das Bild an, um Rauschen zu reduzieren, und berechnet anschließend den Laplace-Operator, also die zweite Ableitung des geglätteten Bildes. Die Nulldurchgänge des Laplace-Ergebnisses entsprechen dabei den Kanten im Bild. [84]

Der Schritt der gaußschen Glättung ist entscheidend, da er hilft, die Rauschempfindlichkeit, die für Ableitungen zweiter Ordnung typisch ist, abzumildern. Durch Variation der Standardabweichung des Gauß-Kernels kann der Operator so angepasst werden, dass Kanten in unterschiedlichen Maßstäben erkannt werden. Diese Multiskalenfähigkeit macht den LoG besonders nützlich für Anwendungen, bei denen Kanten unterschiedlicher Breite erkannt werden müssen. Allerdings ist der LoG-Operator rechnerisch aufwendig, da sowohl die Faltung mit einem großen gaußschen Kernel als auch die Berechnung der zweiten Ableitung notwendig sind. Zudem kann er in Bereichen mit allmählichen Intensitätsübergängen zu fehlerhaften Kanten führen, und seine Leistung hängt stark von der Wahl der Parameter des Gauß-Kernels ab. [86]

3.2.1.3 Canny Edge Detection

Der Canny-Kantendetektor, entwickelt von John Canny im Jahr 1986, zählt bis heute zu den beliebtesten und effektivsten Kantenerkennungsalgorithmen. Er wurde entwickelt, um drei zentrale Kriterien zu optimieren: gute Erkennung durch Minimierung von Fehlalarmen und Auslassungen, gute Lokalisierung, da die erkannten Kanten möglichst nah an den tatsächlichen Kanten liegen sollen, sowie minimale Reaktion, sodass pro Kante nur eine Antwort erfolgt. Der Canny-Operator ist ein hochentwickelter Kantenerkennungsalgorithmus, der eine präzise Kantenlokalisierung bei gleichzeitig geringer Rauschanfälligkeit gewährleistet. Er arbeitet in einer Reihe klar definierter Schritte:

1. **Gaußsche Glättung:** Das Bild wird zunächst mit einem Gauß-Filter geglättet, um das Rauschen zu reduzieren. [83]
2. **Berechnung des Gradienten:** Der Sobel-Operator (oder ein ähnliches Verfahren) wird verwendet, um die Größe und Richtung des Gradienten für jedes Pixel zu berechnen. [83]
3. **Nicht-Maximum-Unterdrückung:** In diesem Schritt werden die Kanten ausgedünnt, indem nur die lokalen Maxima in Gradientenrichtung beibehalten werden. [83]

4. **Hysterese-Schwellenwertbildung:** Die Kanten werden mit zwei Schwellenwerten (hoch und niedrig) abgeschlossen, um starke Kanten von schwachen zu unterscheiden. Schwache Kanten werden nur dann beibehalten, wenn sie mit starken Kanten verbunden sind, wodurch die Fragmentierung verringert wird. [84]

Die Robustheit des Canny-Detektors gegenüber Rauschen und seine Fähigkeit, dünne, gut lokalisierte Kanten zu erzeugen, machen ihn für eine breite Palette von Anwendungen geeignet. Seine Leistung hängt jedoch in hohem Maße von der Wahl der Schwellenwerte ab, die häufig manuell eingestellt werden müssen. Da der Canny-Operator mehrere Stufen mit verschiedenen Parametern umfasst und seine Effektivität eher in diesem systematischen Ansatz als in einer einzigen Definitionsgleichung liegt, kann er bei strukturierten Hintergründen oder Bildern mit geringem Kontrast Probleme bereiten.

3.2.2 Anwendungen in der Hochpräzisionsmesstechnik

Kantenerkennungsalgorithmen spielen eine zentrale Rolle in hochpräzisen Messtechnologien, bei denen die genaue und zuverlässige Extraktion von Objektgrenzen unerlässlich ist. Diese Anwendungen erfordern häufig Subpixel-Genauigkeit und Robustheit gegenüber unterschiedlichen Umweltbedingungen. [85]

Die Kantenerkennung bleibt eine grundlegende Aufgabe der Bildverarbeitung, die die Identifikation von Objektgrenzen und relevanten Bildbereichen ermöglicht. Im Laufe der Jahre hat sich ihre Entwicklung erheblich weiterentwickelt – von klassischen Methoden wie Sobel, Prewitt und Canny bis hin zu fortgeschrittenen, KI-gestützten Verfahren. Forschende arbeiten kontinuierlich an der Verbesserung dieser Algorithmen, um domänenspezifische Herausforderungen in Bereichen wie der medizinischen Bildgebung, Unterwassersicht und Robotik zu bewältigen. [85]

Das Aufkommen von Convolutional Neural Networks (CNNs) hat die Kantenerkennung revolutioniert, da sie die Extraktion semantisch reichhaltiger Merkmale ermöglichen. Mit zunehmender Tiefe der CNN-Architekturen und wachsender Rezeptivfeldgröße erfassen sie schrittweise globale Strukturen und objektbezogene Informationen. Dies hat zu erheblichen Verbesserungen der Erkennungsgenauigkeit geführt. Ein wesentlicher Nachteil dieser tiefen Netzwerke besteht jedoch im Verlust feingranularer Details, insbesondere in den frühen Schichten, da die Merkmalskarten abstrakter werden und die räumliche Auflösung abnimmt. [82]

Um dieser Einschränkung entgegenzuwirken, wurden in jüngerer Zeit Methoden mit Multi-Level-Feature-Aggregation entwickelt, bei denen tiefe semantische Merkmale mit flachen, hochaufgelösten Merkmalen kombiniert werden. Obwohl diese Fusion dazu beiträgt, feinere strukturelle Informationen wiederherzustellen, bringt sie auch eine neue Herausforderung mit sich: Flache Merkmale erfassen meist nur lokale

Intensitätsvariationen, ohne dabei sinnvolle semantische Kontexte zu berücksichtigen, was häufig zur Erkennung von falschen oder vertauschten Kanten führt.

Zur Überbrückung dieser Lücke wurden fortgeschrittene Modelle wie CNNs oder andere neue Architekturen vorgeschlagen. Sie könnten die Kantenerkennungsleistung verbessern, indem sie globalen Kontext und lokale Details effektiv integrieren. Dabei wird eine Dual-Cue-Architektur genutzt, um sicherzustellen, dass die erkannten Kanten sowohl semantisch bedeutsam als auch räumlich präzise sind. [82]

3.2.2.1 Berührungslose dimensionale Inspektion

In der industriellen Fertigung verlassen sich berührungslose dimensionale Prüfsysteme auf die Kantenerkennung, um die physischen Abmessungen von Objekten ohne physischen Kontakt zu messen. Diese Systeme sind entscheidend für die Sicherstellung von Produktqualität und -konsistenz, insbesondere in Branchen, in denen Präzision von höchster Bedeutung ist, wie etwa der Automobil-, Luft- und Raumfahrt-, Medizintechnik- und Elektronikindustrie. [88]

Beispielsweise müssen in der Automobil- oder Luftfahrtindustrie die Maße von bearbeiteten Bauteilen überprüft werden, um sicherzustellen, dass sie strengen Toleranzen entsprechen. Selbst geringfügige Abweichungen können zu Leistungsproblemen oder Sicherheitsrisiken führen, weshalb eine hochpräzise Inspektion unerlässlich ist. Klassische Methoden wie der Canny-Detektor werden aufgrund ihrer Genauigkeit häufig eingesetzt, können jedoch durch KI-basierte Verfahren ergänzt werden, um komplexe Geometrien oder reflektierende Oberflächen zu bewältigen. KI-gestützte Ansätze, wie auf Deep Learning basierende Kantenerkennung und durch neuronale Netze verbesserte Bildverarbeitung, ermöglichen eine adaptive Inspektion, die sich an Schwankungen in Beleuchtung, Materialeigenschaften und Oberflächenstrukturen anpassen kann. [88]

Darüber hinaus wurden fortschrittliche optische Systeme, einschließlich strukturiertem Lichtscanning und digitaler Holographie, in berührungslose Inspektionsprozesse integriert, um Submillimeter-Genauigkeit zu erreichen. Diese Techniken ermöglichen hochgeschwindige, echtzeitfähige Messungen und sind damit ideal für die Inline-Qualitätskontrolle in Produktionsumgebungen mit hohem Durchsatz. Der gPb-Algorithmus (global probability of boundary), der lokale und globale Hinweise kombiniert, hat sich in solchen Anwendungen als vielversprechend erwiesen, da er genauere und kontinuierlichere Kanten liefert, insbesondere bei Objekten mit komplexen oder unregelmäßigen Formen. [88]

Moderne berührungslose Inspektionssysteme integrieren zudem häufig Multi-Sensor-Fusion, bei der Daten von hochauflösenden Kameras, Lasertriangulation und Interferometrie kombiniert werden, um die Messzuverlässigkeit zu erhöhen. Dieser Ansatz minimiert Fehler, die durch Umwelteinflüsse entstehen, und verbessert die Robustheit bei der Erkennung subtiler Maßabweichungen. In Branchen wie der Herstellung medizinischer Geräte, in denen Präzision entscheidend für Funktionalität und

Patientensicherheit ist, spielen diese Technologien eine zentrale Rolle bei der Einhaltung strenger Qualitätsstandards. [87]

Durch den Einsatz von KI, fortschrittlicher Optik und Multi-Sensor-Integration entwickelt sich die berührungslose dimensionale Prüfung stetig weiter und bietet Herstellern ein leistungsfähiges Werkzeug für hochpräzise, nichtinvasive Messungen bei gleichzeitiger Effizienzsteigerung und Reduktion von Produktionsfehlern. [87]

3.2.2.2 Mikro- und Nanostrukturen Detektion

Die Halbleiterindustrie erfordert die Erkennung äußerst feiner Kanten und Muster auf Siliziumwafern, oftmals im Nanometerbereich. Da Halbleiterbauelemente weiterhin schrumpfen, ist die präzise Erkennung von Strukturen entscheidend für die Aufrechterhaltung von Leistung und Zuverlässigkeit. Traditionelle Kantenerkennungsmethoden stoßen hierbei an ihre Grenzen, da sie aufgrund von Rauschen, geringem Kontrast oder Materialeigenschaften solche winzigen Merkmale nicht zuverlässig erfassen können. [86]

Tiefenlern-basierte Ansätze wie HED (Holistically-Nested Edge Detection) oder RCF (Richer Convolutional Features) werden zunehmend eingesetzt, da sie multiskalige Merkmale und kontextuelle Informationen nutzen können, um subtile Kanten zu erkennen. Diese Methoden werden auf hochauflösenden Bildern mit präzisen Annotationen trainiert, um das erforderliche Detailniveau zu erreichen. Zudem wird hyperspektrale Bildgebung in Kombination mit Deep Learning erforscht, um Defekte in Nanostrukturen mit hohem Aspektverhältnis zu erkennen und so die Genauigkeit bei der Identifizierung struktureller Anomalien zu verbessern. [86]

Neben der Kantenerkennung spielen fortschrittliche Messtechniken wie spektroskopische Ellipsometrie, Raman-Spektroskopie und Elektronenmikroskopie eine entscheidende Rolle bei der Charakterisierung von Halbleiter-Nanostrukturen. Diese Verfahren liefern Erkenntnisse über Materialzusammensetzung, Schichtdicke und Defektverteilung und ergänzen die KI-gestützte Bildanalyse. Die optische Scatterometrie, bei der durch Analyse der Fernfeld-Streuung optischer Signale Profilparameter von Nanostrukturen abgeleitet werden, hat sich ebenfalls als wertvolles Werkzeug für zerstörungsfreie Inspektionen etabliert. [87]

Darüber hinaus wurde die strukturlichtgestützte kohärente Fourier-Scatterometrie entwickelt, um die physikalische Parameterbestimmung von Nanostrukturen zu verbessern und eine Inline-Überwachung während der Halbleiterfertigung zu ermöglichen. Diese Technik erlaubt es den Herstellern, eine strenge Qualitätskontrolle aufrechtzuerhalten und gleichzeitig die Fertigungsprozesse zu optimieren. [87]

Durch die Integration von KI-basierter Kantenerkennung, hyperspektraler Bildgebung und fortschrittlichen Messtechniken gelingt es der Halbleiterindustrie, die Grenzen der Präzision bei der Erkennung von Mikro- und Nanostrukturen weiter zu verschieben und

so die Zuverlässigkeit und Effizienz der nächsten Generation elektronischer Geräte sicherzustellen. [87]

3.2.2.3 Geometrivalidierung in der industriellen Qualitätskontrolle

In der Qualitätskontrolle wird die Kantenerkennung eingesetzt, um die Geometrie hergestellter Komponenten mit ihren Konstruktionsvorgaben abzugleichen. Dieser Prozess ist in verschiedenen Branchen unerlässlich, darunter Automobilbau, Luft- und Raumfahrt, medizinische Bildgebung und Elektronik, in denen Präzision entscheidend für Funktionalität und Sicherheit ist. [87]

Beispielsweise müssen in der medizinischen Bildgebung die Konturen von Implantaten oder Prothesen exakt mit ihren vorgesehenen Designs übereinstimmen. Selbst geringfügige Abweichungen können zu Komplikationen beim Patienten führen, weshalb eine Validierung mit hoher Genauigkeit unverzichtbar ist. Strukturierte Kantenerkennungsverfahren wie SE (Structured Edges) nutzen maschinelles Lernen, um Kanten auf Basis lokaler Bildausschnitte vorherzusagen und bieten dadurch Robustheit gegenüber Lichtveränderungen und Verdeckungen. Solche Verfahren werden häufig in automatisierte Inspektionssysteme integriert, um Konsistenz sicherzustellen und menschliche Fehler zu reduzieren. [87]

Über die strukturierte Kantenerkennung hinaus werden fortgeschrittene Techniken wie Deep-Learning-basierte Segmentierung und adaptive Schwellenwertverfahren eingesetzt, um die Genauigkeit bei komplexen Geometrien zu erhöhen. KI-gesteuerte Ansätze ermöglichen Echtzeitanpassungen an Umweltfaktoren und verbessern die Zuverlässigkeit unter dynamischen Fertigungsbedingungen. Darüber hinaus bieten optische Messtechniken wie Laserprofilometrie und strukturierte Lichtabtastung hochauflösende geometrische Validierung und ermöglichen eine Präzision im Submikrometerbereich bei der Bauteilprüfung. [88]

Ein weiterer wichtiger Fortschritt in der industriellen Qualitätskontrolle ist die Multisensorfusion, bei der Daten von hochauflösenden Kameras, Laserdreiecksvermessung und Interferometrie kombiniert werden, um die Messzuverlässigkeit zu verbessern. Dieser Ansatz minimiert Fehler, die durch Materialunregelmäßigkeiten entstehen, und erhöht die Robustheit bei der Erkennung feiner dimensionsbezogener Abweichungen. In Branchen wie der Halbleiterfertigung, in denen Präzision im Nanometerbereich erforderlich ist, spielen diese Technologien eine entscheidende Rolle bei der Einhaltung strenger Qualitätsstandards. [88]

3.2.3 Beschränkungen der klassischen Kantenerkennungsmethoden

Trotz ihrer weitverbreiteten Anwendung leiden klassische Kantenerkennungsverfahren unter mehreren inhärenten Einschränkungen, die ihre Leistungsfähigkeit in realen Szenarien beeinträchtigen können. Diese Techniken, obwohl sie eine Grundlage der

Bildverarbeitung darstellen, haben häufig Schwierigkeiten mit Genauigkeit und Zuverlässigkeit aufgrund verschiedener Einflussfaktoren.

Ein wesentliches Problem ist das Bildrauschen, das zur Fragmentierung von Kanten führen kann, wobei zusammenhängende Kanten in unterbrochene Segmente zerfallen. Dieses Problem tritt besonders bei Bildern geringer Qualität oder hoher Kompression auf, bei denen das Rauschniveau hoch ist. Klassische Verfahren wie die Sobel-, Prewitt- und Canny-Detektoren basieren auf gradientenbasierten Ansätzen und sind daher anfällig für Rauschstörungen. Zwar kann eine Glättung mittels Gauß-Filter einige dieser Effekte mildern, jedoch kann sie auch feine Details verwischen und die Kantenschärfe reduzieren. [81]

Beleuchtungsunterschiede erschweren die Kantenerkennung zusätzlich, da sich durch veränderte Lichtverhältnisse das Erscheinungsbild von Kanten verzerren und die Konsistenz der Erkennung verringern kann. Klassische Methoden gehen häufig von gleichmäßiger Beleuchtung aus und sind daher weniger effektiv in Umgebungen mit Schatten, Reflexionen oder ungleichmäßiger Helligkeit. Adaptive Schwellenwertverfahren wurden eingeführt, um dieses Problem zu adressieren, erfordern jedoch eine sorgfältige Abstimmung, um die Robustheit in unterschiedlichen Szenarien aufrechtzuerhalten. [85]

Eine weitere Einschränkung besteht in der Schwierigkeit, Kanten in komplexen oder texturierten Szenen präzise zu lokalisieren. Klassische Kantendetektoren verlassen sich primär auf Intensitätsgradienten, die möglicherweise nicht ausreichen, um Kanten in Bildern mit komplizierten Mustern oder überlappenden Texturen zu erkennen. Dies kann zu Fehlalarmen oder dem Übersehen kritischer Kanten führen, was sich negativ auf nachgelagerte Anwendungen wie Objekterkennung und Segmentierung auswirkt. [85]

Darüber hinaus erfordern klassische Methoden in der Regel eine sorgfältige Feinabstimmung der Parameter, um Sensitivität und Spezifität ins Gleichgewicht zu bringen. Die Wahl von Schwellenwerten, Kernelgrößen und Filtereinstellungen beeinflusst die Leistung erheblich, und die Ermittlung optimaler Konfigurationen kann zeitaufwendig und abhängig vom jeweiligen Anwendungsfall sein. Diese mangelnde Anpassungsfähigkeit macht klassische Kantenerkennung weniger geeignet für dynamische Umgebungen, in denen sich die Bedingungen häufig ändern. [85]

Zur Überwindung dieser Einschränkungen integrieren moderne Ansätze Verfahren des maschinellen Lernens und Deep Learning, die kontextuelle Informationen und mehrskalige Merkmale nutzen, um die Genauigkeit der Kantenerkennung zu verbessern. Methoden wie Holistically-Nested Edge Detection (HED) und Richer Convolutional Features (RCF) haben durch das Erlernen von Kantenstrukturen aus großen Datensätzen eine überlegene Leistung gezeigt und verringern die Abhängigkeit von manueller Parametereinstellung. [85]

3.2.3.1 Lärmempfindlichkeit

Klassische Operatoren wie Sobel oder Prewitt sind äußerst empfindlich gegenüber Rauschen, was zu fragmentierten oder irreführenden Kanten führen kann. Diese Empfindlichkeit entsteht dadurch, dass diese Operatoren auf gradientenbasierten Methoden beruhen, welche Intensitätsänderungen verstärken und dadurch Rauschen als falsche Kanten interpretieren können. [84]

Ein Beispiel hierfür ist die medizinische Bildgebung, bei der Rauschen von Bildsensoren falsche Kanten erzeugen kann, die echte anatomische Grenzen überdecken. Dieses Problem ist insbesondere bei Anwendungen wie der Tumorerkennung oder der Gefäßbildgebung kritisch, da eine präzise Lokalisierung der Kanten für eine genaue Diagnose unerlässlich ist. Auch in der industriellen Inspektion können Rauschartefakte zu fehlerhaften Messungen führen, was sich negativ auf Qualitätskontrollprozesse auswirkt. [84]

Zwar kann Gaußsche Glättung dieses Problem abschwächen, jedoch kann sie auch echte Kanten verwischen und dadurch die Lokalisierungsgenauigkeit verringern. Um diesen Zielkonflikt zu lösen, wurden adaptive Filtertechniken wie anisotrope Diffusion und bilaterale Filter eingeführt, die Rauschen selektiv glätten, während sie Kantendetails bewahren. Darüber hinaus haben sich wavelet-basierte Entrauschungsmethoden als vielversprechend erwiesen, da sie Bilder in mehrskalige Darstellungen zerlegen und eine gezielte Rauschunterdrückung ermöglichen. [85]

Jüngste Fortschritte im Deep Learning haben die Rauschresistenz in der Kantenerkennung weiter verbessert. Auf großen Datensätzen trainierte Convolutional Neural Networks (CNNs) können lernen, zwischen echten Kanten und Rauschen zu unterscheiden, was die Robustheit in anspruchsvollen Umgebungen deutlich erhöht. Hybride Ansätze, die klassische Kantenerkennung mit KI-gestützter Rauschunterdrückung kombinieren, finden zunehmend Anwendung in Bereichen wie medizinischer Bildgebung, Fernerkundung und automatisierter Inspektion. [85]

Durch die Integration von adaptiven Filtertechniken, wavelet-basierter Entrauschung und KI-basierten Verfahren entwickeln sich moderne Kantenerkennungssysteme stetig weiter und bieten verbesserte Genauigkeit und Zuverlässigkeit unter rauschbehafteten Bedingungen. [85]

3.2.3.2 Einfluss der Lichtverhältnisse

Beleuchtungsvariationen stellen eine erhebliche Herausforderung für die Kantenerkennung dar. Schatten, Reflexionen oder ungleichmäßige Ausleuchtung können Intensitätsgradienten erzeugen, die fälschlicherweise als Kanten interpretiert werden. Im Bereich des autonomen Fahrens beispielsweise können Schatten, die von Bäumen oder Gebäuden geworfen werden, zu fehlerhaften Kantendetektionen führen und somit die Hinderniserkennung beeinträchtigen. Verfahren wie XDoG (eXtended Difference of

Gaussians) versuchen, dieses Problem zu lösen, indem sie die Schwellenwerte dynamisch an den lokalen Kontrast anpassen. Dennoch stoßen sie unter extremen Bedingungen weiterhin an ihre Grenzen. [84]

Die Difference-of-Gaussians-Methode (DoG) ist ein grundlegendes Verfahren in der Kantenerkennung, das Kanten hervorhebt, indem zwei unterschiedlich stark geglättete Versionen eines Bildes voneinander subtrahiert werden. Dieser Vorgang wirkt wie ein Bandpassfilter, der spezifische räumliche Frequenzinformationen – insbesondere dort, wo sich die Intensität rasch ändert – betont, während Rauschen und irrelevante Details herausgefiltert werden. Trotz ihrer Einfachheit dient die DoG-Methode als Basis für zahlreiche weiterentwickelte Algorithmen. [83]

Im Jahr 2007 stellten Kang et al. die FDoG-Methode (Flow-based Difference of Gaussians) vor, um die Einschränkungen des klassischen DoG zu überwinden, das isotrope Filterung verwendet und nicht richtungssensitiv ist. FDoG nutzt richtungsabhängige Filterung durch Berücksichtigung der lokalen Kantenorientierung. Es wird ein sogenannter „Boundary Tangent Flow“ aus dem Eingabebild konstruiert, und die Differenzbildung der Gauss-Filter erfolgt gezielt in der Normalrichtung des Kantenverlaufs. Dieser selektive Ansatz ermöglicht es FDoG, glattere und kontinuierlichere Kanten zu erkennen, während gleichzeitig Rauschen reduziert und Fehlklassifikationen vermieden werden – insbesondere in Bereichen, in denen herkömmliche manuelle Merkmalsdefinitionen an ihre Grenzen stoßen. [83]

Eine weitere Entwicklung stellte im Jahr 2011 XDoG (eXtended DoG) von Winnemöller dar, das auf der Fähigkeit von DoG aufbaut, stilisierte und saubere Konturen zu erzeugen. XDoG führte eine kontinuierliche Schwellwertfunktion sowie einen zusätzlichen Parameter zur Steuerung der Grenzintensität bei der Gauss-Filterung ein. Das Ergebnis ist eine gewichtete Kombination aus der ursprünglichen Gauß-Glättung und der DoG-Ausgabe, die wahrnehmungsrelevante Kantendetails betont und künstlerisch ansprechende Darstellungen ermöglicht. Im Gegensatz zu klassischen Kantenerkennungsverfahren eignet sich XDoG besonders für nicht-photorealistische Darstellungen und erzeugt ästhetisch ansprechende Kantenbilder mit minimalem Nachbearbeitungsaufwand. [83]

3.2.3.3 Fehler bei der Kantenlokalisierung

Klassische Methoden erzeugen häufig Kanten, die mehrere Pixel breit sind, was die exakte Lokalisierung von Objektgrenzen erschwert. Diese Einschränkung ergibt sich daraus, dass traditionelle Kantenerkennungsverfahren auf gradientenbasierten Ansätzen beruhen, die von Natur aus eine gewisse Unschärfe in der Kantenposition mit sich bringen. In Anwendungen, die höchste Präzision erfordern – wie robotergestützte Chirurgie, Halbleiterfertigung oder hochauflösende Mikroskopie – können selbst geringfügige Lokalisierungsfehler gravierende Folgen haben. [88]

In der robotergestützten Chirurgie ist eine Subpixel-Präzision entscheidend, um eine genaue Positionierung der Instrumente zu gewährleisten und Gewebeschäden zu

minimieren. Lokalisierungsfehler können die Genauigkeit von Navigationssystemen beeinträchtigen, was zu unbeabsichtigten Einschnitten oder einer Fehljustierung chirurgischer Werkzeuge führen kann. Zwar hilft die Nicht-Maximum-Unterdrückung im Canny-Detektor dabei, Kanten zu verschmälern, doch hängt das Endergebnis weiterhin von der anfänglichen Gradientenberechnung ab, die möglicherweise nicht präzise genug für sicherheitskritische Anwendungen ist. Zusätzlich können Beleuchtungsunterschiede, Texturen oder Materialeigenschaften die Genauigkeit der Kantenlokalisierung weiter verschlechtern. [88]

Zur Überwindung dieser Herausforderungen wurden fortgeschrittene Verfahren wie aktive Konturmodelle (Snakes) und graphbasierte Segmentierung eingesetzt, um die Kantenlokalisierung zu verfeinern. Diese Methoden berücksichtigen kontextuelle Informationen und ermöglichen eine adaptive Verarbeitung zur Verbesserung der Grenzgenauigkeit. Darüber hinaus nutzen Deep-Learning-basierte Verfahren wie Holistically-Nested Edge Detection (HED) und Richer Convolutional Features (RCF) eine mehrskalige Merkmalsextraktion, um die Präzision gegenüber klassischen Methoden deutlich zu steigern. [88]

In hochpräzisen industriellen Anwendungen wurden Verfahren wie Super-Resolution-Bildgebung und Subpixel-Interpolation in Kantenerkennungs-Workflows integriert, um eine feinere Lokalisierung zu ermöglichen. Diese Ansätze verbessern die Grenzdefinition, reduzieren die Messunsicherheit und steigern die Gesamtexaktheit. [88]

3.2.3.4 Herausforderungen bei der Kalibrierung

Die meisten klassischen Methoden erfordern eine manuelle Parametereinstellung, die zeitaufwändig und stark anwendungsspezifisch sein kann. Beispielsweise können die optimalen Schwellenwerte für den Canny-Detektor zwischen einer gut beleuchteten industriellen Umgebung und einer schwach beleuchteten Außenaufnahme erheblich variieren. Diese mangelnde Anpassungsfähigkeit begrenzt die Skalierbarkeit dieser Verfahren. [84]

Klassische Kantenerkennungstechniken, obwohl weit verbreitet, weisen mehrere bedeutende Einschränkungen auf, die ihre Wirksamkeit beeinträchtigen. Ein zentrales Problem ist die Kantenfragmentierung, verursacht durch Bildrauschen, welches durchgehende Kanten in getrennte Fragmente aufbricht und so eine weiterführende Analyse erschwert. Auch Variationen in der Beleuchtung stellen Herausforderungen dar, da Lichtänderungen das Kantenbild verzerren und die Detektionsgenauigkeit verringern können. Die präzise Lokalisierung von Kanten bleibt insbesondere bei Bildern mit komplexen Texturen oder subtilen Gradienten schwierig. Darüber hinaus erfordern diese Methoden oft eine Feinabstimmung mehrerer Parameter wie Schwellenwerte und Filtergrößen, um die Leistung für spezifische Bilder oder Bedingungen zu optimieren – ein Prozess, der sowohl zeitintensiv als auch anspruchsvoll sein kann. Kalibrierungsprobleme verschärfen die Situation zusätzlich, da Inkonsistenzen in Bildaufnahmegeräten oder Umgebungsfaktoren zu Ungenauigkeiten bei der Kantenlokalisierung und -messung führen können, insbesondere in Anwendungen mit

hohen Präzisionsanforderungen. Die Überwindung dieser Einschränkungen ist entscheidend, um die Robustheit und Zuverlässigkeit der Kantenerkennung zu verbessern. [84]

3.2.4 AI-gestützte Verbesserungen bei der Kantenerkennung

Der Aufstieg des Deep Learnings hat bahnbrechende Fortschritte in der Kantenerkennung ermöglicht, indem Modelle komplexe Merkmale erlernen und sich an vielfältige Szenarien anpassen können. Traditionelle Kantenerkennungsverfahren wie Sobel und Canny basieren auf vordefinierten Filtern und gradientenbasierten Ansätzen, die bei Rauschen, Beleuchtungsvariationen und komplexen Texturen an ihre Grenzen stoßen können. Im Gegensatz dazu nutzen Deep-Learning-Techniken große annotierte Datensätze, wie BSDS500, um hierarchische Repräsentationen von Kanten zu erlernen, was die Genauigkeit und Robustheit signifikant verbessert. [86]

Convolutional Neural Networks (CNNs) stehen im Zentrum dieses Fortschritts und zeigen aufgrund ihrer Fähigkeit, semantische und räumliche Merkmale hierarchisch zu extrahieren, starke Leistungen in visuellen Aufgaben. Im Unterschied zu klassischen Methoden können CNN-basierte Modelle sich an unterschiedliche visuelle Kontexte anpassen, was sie besonders effektiv in Anwendungen wie der medizinischen Bildgebung, autonomen Navigation und industrieller Inspektion macht. Neuere Deep-Learning-Methoden wie EDTER (Edge Detection with Transformer) und BiMLA (Bidirectional Multi-Level Attention) haben die Kantenlokalisierung weiter verbessert, indem sie mehrstufige Merkmale integrieren und Rauschinterferenzen minimieren. [82]

Über die Standard-Deep-Netzwerke hinaus wurden Optimierungsalgorithmen mit der Kantenerkennung kombiniert, um zusätzliche Verbesserungen zu erzielen. Einige Forscher haben hybride Algorithmen entwickelt, die geführte Bildfilterung mit Ameisen-Kolonien-Optimierung verbinden, wodurch glattere Kantenkarten und bessere Rauschunterdrückung im Vergleich zu herkömmlichen Ansätzen erreicht werden. Zudem haben sich selbstüberwachte Lernverfahren etabliert, die es Modellen ermöglichen, die Kantenerkennung ohne umfangreiche beschriftete Datensätze zu verfeinern. [86]

Transformer-basierte Architekturen gewinnen ebenfalls an Bedeutung in der Kantenerkennung, da sie besonders gut darin sind, Langzeitabhängigkeiten und globalen Kontext zu modellieren. Durch die Verarbeitung fein abgestufter Bildausschnitte und den Einsatz eines Merkmalsfusionsmoduls kombinieren diese Modelle lokaltexturale und globale semantische Informationen effektiv, was zu schärferen und präziseren Kantenkarten führt. Darüber hinaus ermöglichen mehrskalige Merkmalsextraktionstechniken Deep-Learning-Modellen, Kanten in verschiedenen Auflösungen zu erfassen und so die Leistung in komplexen Szenen zu verbessern. [86]

Mit der fortschreitenden Entwicklung der KI wird erwartet, dass Kantenerkennungsmethoden noch präziser, anpassungsfähiger und effizienter werden, was Fortschritte in Bereichen wie der biomedizinischen Bildgebung, Robotik und hochauflösender Satellitenanalyse ermöglicht. [86]

3.2.4.1 Convolutional Neural Networks (CNNs) für die Kantenerkennung

Convolutional Neural Networks (CNNs) sind zur Grundlage moderner Kantenerkennung geworden, da sie hierarchische Merkmale direkt aus Daten lernen können. Im Gegensatz zu klassischen Kantenerkennungsmethoden, die auf vordefinierten Filtern und gradientenbasierten Verfahren basieren, ermöglichen CNNs die automatische Extraktion bedeutungsvoller Merkmale aus Bildern und sind somit hochgradig anpassungsfähig an unterschiedliche visuelle Kontexte. [82]

Bahnbrechende Arbeiten wie Holistically-Nested Edge Detection (HED) führten ein vollständig end-to-end trainierbares Netzwerk ein, das Kanten direkt aus Rohbildern vorhersagt und dabei multiskalige Merkmale mittels Deep Supervision nutzt. Dieser Ansatz verbesserte die Kantenerkennungsgenauigkeit erheblich, indem tiefere Schichten Kantenvorhersagen verfeinerten und gleichzeitig feine Details erhalten blieben. [82]

Nachfolgende Modelle wie Richer Convolutional Features (RCF) und das Bi-Directional Cascade Network (BDCN) steigerten die Leistung weiter durch die Aggregation von Merkmalen aus allen Faltungsschichten, wodurch sowohl feine Details als auch hochstufige semantische Informationen erfasst werden. RCF verwendet eine Fusion von Merkmalen auf mehreren Ebenen zur Verbesserung der Kantenlokalisierung, während BDCN bidirektionale Verfeinerungsmechanismen einführt, um Kantenkontinuität zu erhöhen und Rauschstörungen zu reduzieren. [82]

Neben diesen Architekturen wurden jüngst auch transformerbasierte Modelle für die Kantenerkennung untersucht, welche durch globale Kontextmodellierung die Robustheit in komplexen Szenen verbessern. Zudem haben sich selbstüberwachte Lernverfahren etabliert, die CNNs ermöglichen, Kanten ohne umfangreiche beschriftete Datensätze zu verfeinern. [82]

Um die Genauigkeit der Kantenerkennung weiter zu erhöhen, integrierten Forscher Optimierungsalgorithmen wie geführte Bildfilterung und Ameisen-Kolonien-Optimierung, wodurch glattere Kantenkarten und eine bessere Rauschunterdrückung als bei konventionellen Verfahren erzielt werden. Diese hybriden Methoden kombinieren Deep Learning mit klassischen Bildverarbeitungstechniken, um Präzision und Anpassungsfähigkeit zu maximieren. [81]

Mit der fortschreitenden Entwicklung der künstlichen Intelligenz wird erwartet, dass CNN-basierte Kantenerkennungsmethoden noch präziser, effizienter und widerstandsfähiger gegenüber schwierigen Bildbedingungen werden und so Fortschritte in Bereichen wie medizinischer Bildgebung, autonomer Navigation und hochauflösender Satellitenanalyse ermöglichen. [81]

3.2.4.2 KI-gestütztes Training für die Kantendetektion

Convolutional Neural Networks (CNNs) sind zur Grundlage moderner Kantenerkennung geworden, da sie hierarchische Merkmale direkt aus Daten lernen können. Im Gegensatz zu klassischen Kantenerkennungsmethoden, die auf vordefinierten Filtern und gradientenbasierten Verfahren basieren, ermöglichen CNNs die automatische Extraktion bedeutungsvoller Merkmale aus Bildern und sind somit hochgradig anpassungsfähig an unterschiedliche visuelle Kontexte. [88]

Bahnbrechende Arbeiten wie Holistically-Nested Edge Detection (HED) führten ein vollständig end-to-end trainierbares Netzwerk ein, das Kanten direkt aus Rohbildern vorhersagt und dabei multiskalige Merkmale mittels Deep Supervision nutzt. Dieser Ansatz verbesserte die Kantenerkennungsgenauigkeit erheblich, indem tiefere Schichten Kantenvorhersagen verfeinerten und gleichzeitig feine Details erhalten blieben. [89]

Nachfolgende Modelle wie Richer Convolutional Features (RCF) und das Bi-Directional Cascade Network (BDCN) steigerten die Leistung weiter durch die Aggregation von Merkmalen aus allen Faltungsschichten, wodurch sowohl feine Details als auch hochstufige semantische Informationen erfasst werden. RCF verwendet eine Fusion von Merkmalen auf mehreren Ebenen zur Verbesserung der Kantenlokalisierung, während BDCN bidirektionale Verfeinerungsmechanismen einführt, um Kantenkontinuität zu erhöhen und Rauschstörungen zu reduzieren.

Neben diesen Architekturen wurden jüngst auch transformerbasierte Modelle für die Kantenerkennung untersucht, welche durch globale Kontextmodellierung die Robustheit in komplexen Szenen verbessern. Zudem haben sich selbstüberwachte Lernverfahren etabliert, die CNNs ermöglichen, Kanten ohne umfangreiche beschriftete Datensätze zu verfeinern.

Um die Genauigkeit der Kantenerkennung weiter zu erhöhen, integrierten Forscher Optimierungsalgorithmen wie geführte Bildfilterung und Ameisen-Kolonien-Optimierung, wodurch glattere Kantenkarten und eine bessere Rauschunterdrückung als bei konventionellen Verfahren erzielt werden. Diese hybriden Methoden kombinieren Deep Learning mit klassischen Bildverarbeitungstechniken, um Präzision und Anpassungsfähigkeit zu maximieren. [89]

Mit der fortschreitenden Entwicklung der künstlichen Intelligenz wird erwartet, dass CNN-basierte Kantenerkennungsmethoden noch präziser, effizienter und widerstandsfähiger gegenüber schwierigen Bildbedingungen werden und so Fortschritte in Bereichen wie medizinischer Bildgebung, autonomer Navigation und hochauflösender Satellitenanalyse ermöglichen. [89]

3.2.4.3 Erweiterte AI-Modelle

Aktuelle Fortschritte umfassen transformerbasierte Modelle wie EDTER (Edge Detection TransformER), die Self-Attention-Mechanismen nutzen, um langfristige Abhängigkeiten und globalen Kontext zu erfassen. Die zweistufige Architektur von EDTER verarbeitet zunächst grobe Bildausschnitte zur Erfassung des globalen Kontexts und verfeinert anschließend die Kanten mit feinen Ausschnitten. Dadurch erzielt das Modell Spitzenleistungen auf Benchmarks wie BSDS500. [86]

Ein weiteres bemerkenswertes Modell ist PiDiNet (Pixel Difference Network), das durch den Einsatz leichter Faltungsschichten auf Effizienz optimiert ist und eine Echtzeit-Kantenerkennung ermöglicht, ohne die Genauigkeit zu beeinträchtigen.

Im Bereich der KI-gestützten Kantenerkennung existieren zahlreiche Modelle. Im Folgenden werden wir EDTER näher betrachten: Das erste vollständig transformerbasierte Modell für Kantenerkennung, das globale Kontextmodellierung in zwei Stufen nutzt, ein Feature-Fusion-Modul (FFM) einsetzt und herausragende Performance bietet:

EDTER (Edge Detection TransformER)

- **Erstes transformerbasiertes Kantenerkennungsmodell**, das globalen Kontext (Stufe I) und feinkörnige lokale Merkmale (Stufe II) in einem zweistufigen Framework kombiniert. [86]
- Der **Bi-directional Multi-Level Aggregation (BiMLA) Decoder** verbessert kantenbewusste Features durch Kombination von Top-Down- und Bottom-Up-Pfaden und erhält dünne Kanten besser als herkömmliche CNNs. [86]
- Übertrifft CNN-basierte Modelle wie HED und RCF auf Benchmarks wie **BSDS500** und **NYUDv2** mit höheren Precision-Recall-Kurven und zeigt eine robuste Leistung bei Rauschen und komplexen Hintergründen. [86]

Global Context Modeling (Stufe I)

- Zerlegt Bilder in grobkörnige Patches (16×16) und verarbeitet diese mit einem globalen Transformer-Encoder, um langfristige Abhängigkeiten (z. B. Objektformen) zu erfassen. [86]
- Nutzt den innovativen **BiMLA-Decoder** zur Verschmelzung hierarchischer Merkmale aus mehreren Transformer-Schichten, was die Kontinuität der Kanten bewahrt. [86]

Lokale Verfeinerung (Stufe II)

- Verarbeitet feinkörnige Patches (8×8) mit einem lokalen Transformer, um dünne Kanten wiederherzustellen und gleichzeitig den hohen Rechenaufwand einer pixelgenauen Aufmerksamkeit zu vermeiden. [86]

- Das **Feature Fusion Module (FFM)** kombiniert globale und lokale Features und verbessert so die Schärfe der Kanten (Abbildung 1 der Publikation zeigt klarere Kanten im Vergleich zu CNNs). [86]

Leistung

- Übertrifft CNN-Modelle auf dem BSDS500-Datensatz mit einem ODS-F-Maß von 0,828 sowie auf NYUDv2 um 3–5 % und demonstriert eine überlegene Fähigkeit, semantische Grenzen und Rauschen zu handhaben. [86]

3.2.5 Hybride Ansätze: Kombination von klassischen und AI-Methoden

Hybridmethoden in der Kantenerkennung verbinden klassische und KI-basierte Techniken, um deren jeweilige Stärken zu nutzen und so die Robustheit, Anpassungsfähigkeit und Effizienz zu steigern. Während klassische Verfahren wie Sobel oder Canny auf Gradienten basieren und oft durch Rauschen, Beleuchtungsunterschiede und komplexe Texturen beeinträchtigt werden, können Deep-Learning-Methoden durch Extraktion von mehrskaligen Merkmalen und Kontextinformationen präzisere Kantenerkennung ermöglichen. [88]

Typische Hybridansätze sind:

- **Kombination klassischer Detektoren mit Deep Learning:**
Beispielhaft sind Multi-Stage-Learning-Frameworks, die CNNs zur Merkmalsextraktion mit SVM-Klassifikatoren verbinden. Dadurch werden Kantengenauigkeit und Strukturtreue verbessert, und die Entkopplung von Merkmalsrepräsentation und Klassifikation erhöht die Interpretierbarkeit. [88]
- **Optimierungsalgorithmen zur Verbesserung klassischer Methoden:**
Geführte Bildfilterung zusammen mit Ameisen-Kolonien-Optimierung erzeugt glattere Kanten und unterdrückt Rauschen effizienter. Wavelet-basierte Hybridmodelle koppeln Laplace-of-Gaussian-Filter mit Wavelet-Transformationen, um Kantenkontinuität und visuelle Klarheit zu steigern. [87]
- **Anwendungen in der Bildsteganographie:**
Kombinationen aus Canny- und Sobel-Operatoren mit Medianfiltern verbessern die Kantenerkennung und bewahren gleichzeitig die Bildqualität beim Einbetten von Informationen. Edge-preserving Filter zusammen mit Type-1-Fuzzy-Logik erhöhen die Robustheit in verrauschten Umgebungen. [87]

Durch Multi-Sensor-Fusion, adaptive Filter und KI-gestützte Optimierungen entwickeln sich Hybrid-Kantendetektionssysteme stetig weiter und bieten verbesserte Genauigkeit und Stabilität in Anwendungsfeldern wie medizinischer Bildgebung, autonomer Navigation und industrieller Inspektion. [87]

3.2.5.1 Hybrid edge detection: classic filtering and CNN refinement

Eine häufig angewandte hybride Strategie beginnt mit klassischen Methoden wie der Canny-Filterung, um initiale Kantenkarten zu erzeugen, die anschließend durch ein **Convolutional Neural Network (CNN)** verfeinert werden. Diese Kombination nutzt die Rauschresistenz und Interpretierbarkeit klassischer Filter sowie die adaptive Präzision moderner Deep-Learning-Methoden. Diese Strategie vereint die Stärken traditioneller und KI-basierter Techniken, wodurch sowohl Robustheit gegenüber Rauschen als auch höhere Kantenpräzision erreicht wird. [82]

Beispielsweise nutzt **DexiNed (Dense Extreme Inception Network for Edge Detection)** diesen Ansatz, um dünne, präzise Kanten bei gleichzeitiger Beibehaltung der Rauschunterdrückung des Canny-Detektors zu generieren. Im Gegensatz zu rein CNN-basierten Modellen benötigt DexiNed keine vortrainierten Gewichte und wird direkt trainiert, was eine gute Generalisierbarkeit über verschiedene Datensätze hinweg ermöglicht¹. Die CNN-Komponente lernt, Lücken zu schließen, fehlerhafte Kanten zu entfernen und die Kantenkontinuität zu verbessern, was zu saubereren und zuverlässigeren Ergebnissen führt. [82]

Jenseits von DexiNed repräsentiert **EDTER** einen rein transformer-basierten Ansatz. Obwohl EDTER keine explizite CNN-Integration vorsieht, wurde in der Forschung vorgeschlagen, dass eine Kombination von CNN- und Transformer-Architekturen durch Feature-Fusion die Kantenlokalisierung weiter verbessern könnte. Transformer erfassen besonders effektiv langreichweitige Abhängigkeiten und globalen Kontext, während CNNs lokale Texturen und feine Details extrahieren – ihre Kombination eröffnet somit vielversprechende Forschungsrichtungen. [86]

Derartige Hybridstrategien sind besonders wertvoll für Anwendungen mit hohen Anforderungen an die Kantendetektion, wie medizinische Bildgebung, autonome Navigation oder industrielle Inspektion. Durch die Integration klassischer Filterverfahren mit Deep-Learning-Optimierungen entwickeln sich moderne Kantenerkennungssysteme stetig weiter und bieten verbesserte Genauigkeit, Anpassungsfähigkeit und Robustheit. [86]

3.2.5.2 AI-Guided Feature Enhancement

Methoden wie **AMH-Net (Attention-Guided Multi-Scale Hybrid Network)** integrieren Aufmerksamkeitsmechanismen, um relevante Kanten hervorzuheben und Rauschen zu unterdrücken. Diese Modelle nutzen Multi-Scale-Feature-Fusion, um die Kantendetektion dynamisch an verschiedene Bildbedingungen anzupassen und gleichzeitig Robustheit zu gewährleisten. Durch aufmerksamkeitsgesteuerte Verarbeitung verbessert AMH-Net die Kantenklarheit und reduziert Störungen durch Hintergrundtexturen und Beleuchtungsvariationen. [89]

Solche Modelle verwenden häufig klassische Operatoren als Vorverarbeitungsschritt, um die Rechenlast zu verringern, gefolgt von einer **KI-basierten Nachbearbeitung** für

feinere Details. Beispielsweise können Canny- oder Sobel-Filter zunächst grobe Kantenkarten extrahieren, die anschließend durch Deep-Learning-basierte Merkmalsverfeinerung optimiert werden. Dieser hybride Ansatz ermöglicht eine effiziente Kantendetektion bei gleichbleibend hoher Präzision. [89]

Aufmerksamkeitsmechanismen – wie Self-Attention-Layer und kanalweise Feature-Gewichtung – helfen KI-Modellen, sich auf relevante Kantenstrukturen zu konzentrieren und Rauschen zu unterdrücken. Zudem wurden Transformer-Architekturen für die Kantendetektion untersucht, da sie ein verbessertes globales Kontextverständnis und die Erfassung langreichweitiger Abhängigkeiten ermöglichen. [89]

Diese Kombination ist besonders nützlich für Echtzeitanwendungen wie Videoüberwachung, Augmented Reality und autonome Navigation, bei denen Kantendetektion sowohl präzise als auch recheneffizient sein muss. Durch die Integration von Multi-Scale-Feature-Fusion, aufmerksamkeitsgesteuerter Verfeinerung und hybriden KI-klassischen Verarbeitungsmethoden entwickeln sich moderne Kantendetektionssysteme stetig weiter und bieten verbesserte Präzision und Anpassungsfähigkeit in verschiedenen Bildumgebungen. [89]

3.2.5.3 Erreichen von Präzision im Nanometerbereich

In hochpräzisen Bereichen wie der Halbleiterinspektion integrieren hybride Modelle klassische Kantenerkennung nahtlos mit Deep Learning, um Subpixel-Genauigkeit zu erreichen. Traditionelle Verfahren wie die **Laplacian-of-Gaussian-(LoG)**-Filterung dienen als erster Schritt zur Hervorhebung potenzieller Kanten, die anschließend von **CNNs**, welche auf nanoskalige Muster trainiert sind, validiert und verfeinert werden. Dieser Ansatz minimiert Fehlalarme und gewährleistet gleichzeitig die Erkennung echter Merkmale – ein entscheidender Faktor in der Halbleiterfertigung, bei der bereits kleinste Defekte die Leistungsfähigkeit der Bauteile beeinträchtigen können. [89]

Zur weiteren Verbesserung der Präzision wurden Super-Resolution-Bildgebungstechniken erforscht, die auf wellenletzenbasierter Rauschunterdrückung und Multi-Skalen-Feature-Fusion basieren, um die Kantengenauigkeit zu verfeinern. Zusätzlich wurden **Elektronenstrahlinspektion (EBI)** und **Rasterkraftmikroskopie (AFM)** in die Workflows zur Fehlererkennung in Halbleitern integriert und bieten eine Nanometerauflösung zur Identifikation struktureller Anomalien. [88]

Trotz dieser Fortschritte bestehen noch einige Einschränkungen. So sind beispielsweise die von **EDTER** erzeugten Kanten häufig mehrere Pixel breit und erreichen nicht die ideale Ein-Pixel-Präzision, die für die Detektion ultrafeiner Strukturen erforderlich ist. Zukünftige Forschungen könnten sich daher auf Nachbearbeitungstechniken wie Non-Maximum-Suppression oder hybride **CNN-Transformer-Architekturen konzentrieren**, um dünnere und präzisere Kanten zu erzielen. Darüber hinaus könnten selbstüberwachtes Lernen und adaptive Schwellenwertverfahren die Kantenglättung weiter verbessern, indem sie die Erkennungsparameter dynamisch an kontextuelle Bildmerkmale anpassen. [89]

Da die Halbleiterfertigung zunehmend auf Sub-10-nm-Knoten voranschreitet, wird die Nachfrage nach hochpräziser Defektinspektion weitere Innovationen in KI-gestützter Kantenerkennung, multimodaler Sensorfusion und quantenunterstützten Bildgebungstechniken vorantreiben. Diese Entwicklungen werden höhere Ausbeuten, geringeren Materialverlust und eine verbesserte Zuverlässigkeit von Halbleiterbauteilen der nächsten Generation sicherstellen. [88]

3.2.6 Die Zukunft der Kantenerkennung: Mehr Präzision und Anpassungsfähigkeit

Der Übergang von klassischen Kantenerkennungsverfahren zu CNN-basierten Ansätzen markiert einen Paradigmenwechsel hin zu robusteren, präziseren und flexibleren Systemen. Innovationen wie **Holistically-Nested Edge Detection (HED)** und die Fusion von Multi-Skalen-Antworten haben die Kantengenauigkeit, Konsistenz und Rechenleistung erheblich verbessert. Diese Fortschritte ermöglichen es Modellen, komplexe Muster zu erlernen, sich an verschiedenste Bildgebungsbedingungen anzupassen und multimodale Datenquellen für eine bessere Leistung zu integrieren. [89]

Mit Blick auf die Zukunft werden selbstüberwachtes Lernen, hybride Intelligenzansätze und weiterentwickelte Architekturoptimierungen die Kantenerkennung kontinuierlich verfeinern. Die Kombination von Deep Learning mit Fuzzy-Logik, multimodaler Fusion und **gerichteten azyklischen Graphen (DAG)** wird die Präzision weiter steigern und Kantenerkennungssysteme widerstandsfähiger gegenüber Rauschen, Beleuchtungsschwankungen und komplexen Texturen machen. [89]

Da KI-gestützte Kantenerkennung sich fortlaufend weiterentwickelt, werden ihre Anwendungen sich auf Bereiche wie Halbleiterfertigung, medizinische Bildgebung, autonome Navigation und industrielle Inspektion ausweiten. Durch die Verbindung klassischer Methoden mit modernsten KI-Techniken steht die Branche kurz davor, Nanometer-Präzision zu erreichen und so neue Möglichkeiten für die hochauflösende Merkmalerkennung unter anspruchsvollsten Bedingungen zu erschließen. [89]

3.3 Weitere wichtige Anwendungen

Moderne Messsysteme nutzen zunehmend Künstliche Intelligenz, um traditionelle Einschränkungen bei der Datenqualität, Sensorempfindlichkeit und Betriebsüberwachung zu überwinden. Über die grundlegenden Anwendungen in der Objektlokalisierung und Regressionsmodellierung hinaus bieten KI-gesteuerte Techniken nun transformative Verbesserungen in vielen kritischen Bereichen. Über die Objektlokalisierung und Regressionsmodelle hinaus bieten KI-gesteuerte Messtechnologien robuste Verbesserungen bei der Datenverarbeitung, Systemgenauigkeit und prädiktiven Zuverlässigkeit. Diese Fortschritte betreffen die Signalintegrität, Sensorleistung und Anomalieerkennung und gewährleisten präzise und adaptive Reaktionen in verschiedenen

Branchen. Von der Unterdrückung von Signalrauschen bis zur Sensorkalibrierung mittels Deep Learning verfeinert KI Messtechniken, indem sie komplexe Muster erkennt und Fehler vorhersagt, bevor diese die Systemleistung beeinträchtigen. [49]

Praktische Anwendungen von CNN-basierter Lokalisierung umfassen Roboterarme, die Objekte auf Förderbändern erkennen und greifen [33], Drohnen, die Flugrouten basierend auf YOLO-abgeleiteten Orientierungspunkten anpassen, und intelligente Fabriken, die Teile und Defekte mit Hochgeschwindigkeitskameras und eingebetteten Bildverarbeitungsprozessoren verfolgen [38].

3.3.1 Signalrauschunterdrückung

Deep-Learning-Architekturen trennen effektiv sinnvolle Signale von Rauschen in Umgebungen mit niedrigen Signal-Rausch-Verhältnissen. Anwendungen mit hohem Rauschen umfassen die Vibrationsanalyse in der vorausschauenden Wartung, wo rekurrente neuronale Netze eine Rauschunterdrückung von >90 % bei der Überwachung rotierender Maschinen erreichen.

Lernalgorithmen könnten auf vielfältige Weise zur Verbesserung der Genauigkeit und Zuverlässigkeit von IoT-Lokalisierungssystemen eingesetzt werden. Einige dieser Anwendungen sind wie folgt zusammengefasst:

- **Kalibrierung:** Lernalgorithmen können zur Kalibrierung von Sensoren und anderen IoT-Gerätekomponenten verwendet werden, um sicherzustellen, dass diese korrekt funktionieren und genaue Daten liefern. Dies kann dazu beitragen, die Gesamtgenauigkeit der Standortschätzungen zu verbessern. [65]
- **Rauschunterdrückung:** Algorithmen des maschinellen Lernens können verwendet werden, um Rauschen und andere Fehlerquellen aus Daten von IoT-Geräten zu entfernen. Dies kann dazu beitragen, die Genauigkeit von Standortschätzungen zu verbessern, indem die Auswirkungen von Fehlern und anderen Faktoren, die die Daten verzerren können, reduziert werden. Algorithmen des maschinellen Lernens können verwendet werden, um die relevantesten Merkmale in von IoT-Geräten gesammelten Daten zu identifizieren, wodurch die Genauigkeit der Standortschätzung verbessert wird, indem sich auf die wichtigsten Faktoren konzentriert wird. [49]
- **Modellauswahl:** Algorithmen des maschinellen Lernens können verwendet werden, um das beste Modell oder die beste Kombination von Modellen für eine bestimmte Anwendung zu identifizieren, wodurch die Genauigkeit der Standortschätzung verbessert wird, indem das beste Modell ausgewählt wird, das zu den Daten passt. [34]
- **Verbesserung der Genauigkeit:** Große Datenmengen können von Algorithmen des maschinellen Lernens analysiert werden, um genauere Schätzungen des Gerätestandorts zu liefern. [33]
- **Automatisierung des Lokalisierungsprozesses:** Maschinelles Lernen hat das Potenzial, den Prozess der Bestimmung des Gerätestandorts zu automatisieren und somit die Notwendigkeit manueller Eingaben zu eliminieren.

- **Anpassung an Umgebungsveränderungen:** Um genauere Standortschätzungen zu liefern, können sich Algorithmen des maschinellen Lernens an Umgebungsveränderungen anpassen, wie z.B. neue Hindernisse oder Änderungen der Signalstärke. [51]

In einer Studie untersuchten Forscher die Rauschunterdrückung und Auflösungsverbesserung in der PET-Bildgebung. Die Positronen-Emissions-Tomographie (PET)-Bildgebung steht vor inhärenten Herausforderungen im Zusammenhang mit Rauschen und räumlicher Auflösung, die die quantitative Genauigkeit in der medizinischen Diagnostik beeinflussen. Traditionelle Techniken, wie die quadratische Straffung und die Gaußsche Filterung, wurden zur Minderung dieser Probleme eingesetzt. KI-basierte Methoden, insbesondere Convolutional Neural Networks (CNNs), haben jedoch die PET-Bildverarbeitung transformiert, indem sie direkte Abbildungen zwischen verrauschten und sauberen Bildern lernen. [64]

Moderne Architekturen umfassen:

- **3D-CNN-Modelle:** Bieten trotz hoher Rechenanforderungen überlegene Leistung.
- **Hybride 2D-3D-Netzwerke:** Integrieren dimensionale Merkmale für bessere Ergebnisse.
- **Unüberwachtes und selbstüberwachtes Lernen:** Nutzen Populationsmerkmale zur Verfeinerung verrauschter Daten. [19]

Aufkommende Paradigmen, wie föderiertes Lernen für den Datenschutz in mehreren Zentren und Reinforcement Learning für die adaptive Verarbeitung, verbessern die Zuverlässigkeit der PET-Bildgebung weiter. Da KI-gesteuerte Techniken sich ständig weiterentwickeln, werden Transferlernen, Datenharmonisierung und erklärbare KI entscheidende Rollen bei der Erzielung klinisch signifikanter Verbesserungen spielen.

KI-gesteuerte Entrauschungstechniken in der PET-Bildgebung basieren überwiegend auf überwachtem Lernen, wobei 3D-U-Net-Architekturen weit verbreitet sind. Diese Modelle verwenden typischerweise einen L2-Verlust, oft kombiniert mit perzeptuellen oder adversariellen Zielen, um die Bildklarheit und diagnostische Genauigkeit zu verbessern. [64]

Herausforderungen und zukünftige Richtungen Trotz ihres Erfolgs steht die KI-gesteuerte PET-Entrauschung vor Problemen der Generalisierbarkeit, hohen Rechenanforderungen und potenzieller GAN-bedingter Überglättung. Das Feld verschiebt sich hin zu hybriden Architekturen, die multimodale Daten und physikalische Einschränkungen für eine verbesserte klinische Anwendbarkeit integrieren. [64]

3.3.2 Sensorkalibrierung

Da die Messtechnik ein integraler Bestandteil der Automatisierung, Robotik und industriellen Systeme wird, wächst der Bedarf an präzisen und adaptiven Sensordaten. Sensoren unterliegen jedoch Fehlern aufgrund von Umgebungsveränderungen, Alterung und Signalrauschen, wodurch traditionelle Kalibrierungsmethoden – die oft manuell und statisch sind – für Echtzeitanwendungen unzureichend werden.

Deep Learning transformiert die Sensorkalibrierung durch:

- **Modellierung nichtlinearer Beziehungen** zwischen Rohsensorausgaben und wahren Werten.
- **Ermöglichung kontinuierlicher, In-situ-Kalibrierung** ohne Betriebsunterbrechung.
- **Verbesserung der Genauigkeit** bei gleichzeitiger Reduzierung der Wartungskosten.

Die neuronale netzbasierte Kalibrierung ist besonders nützlich in der Industrieautomation, autonomen Fahrzeugen und Präzisionsfertigung und bietet skalierbare und adaptive Lösungen. Dieser Abschnitt wird Schlüsseltechniken, Architekturen und reale Anwendungen untersuchen, die KI für eine verbesserte Sensorkalibrierungsleistung unter dynamischen Bedingungen nutzen. [5]

Eine der wichtigsten Kalibrierungsmethoden sind Drahtlose Sensornetzwerke (WSNs), die für die Umweltüberwachung, intelligente Städte und Präzisionslandwirtschaft von entscheidender Bedeutung sind und Echtzeit-Raum- und Zeitmessungen ermöglichen. Sensor-Drift – eine allmähliche Abweichung von genauen Messwerten aufgrund von Umgebungsveränderungen oder Hardwareverschleiß – stellt jedoch eine große Herausforderung bei großflächigen Implementierungen dar, bei denen eine manuelle Neukalibrierung unpraktisch ist. Traditionelle Blind-Kalibrierungsmethoden basieren auf festen Annahmen wie linearen Signalsubräumen oder dichter Sensorplatzierung, was die Anpassungsfähigkeit einschränkt. [39]

PRNet: KI-gesteuerte Sensorkalibrierung PRNet (Projection-Recovery Network) ist ein tiefes, vollständig faltendes Netzwerk, das entwickelt wurde, um die Blind-Kalibrierung in WSNs zu automatisieren und wichtige Herausforderungen zu bewältigen:

- **Merkmalextraktion ohne vorherige Modelle:** Im Gegensatz zu unterraumgestützten Methoden, die Linearität annehmen, lernt PRNet räumlich-zeitliche Korrelationen direkt aus Sensordaten. Es verwendet eine Projektionsschicht, um Driftkomponenten zu isolieren, und Wiederherstellungsschichten, um saubere Signale zu rekonstruieren.
- **Dateneffizienz:** Um begrenzte reale Trainingsdaten zu überwinden, synthetisiert PRNet Trainingsbeispiele, indem es kurzfristige Messungen nach der Bereitstellung mit simulierten Driftmustern erweitert.

Methodik & Architektur

- **Projektionsschicht:** Bildet verdriftete Messungen in einen Merkmalsraum ab, in dem Drift und Signal trennbar sind.
- **Wiederherstellungsschichten:** Führen extrahierte Merkmale zusammen, um die Drift abzuschätzen, während Batch-Normalisierung für stabiles Training verwendet wird.
- **Sensormanipulation:** Optimiert die Eingabetensorstruktur durch Neuordnung benachbarter Sensoren, um lokale Korrelationen zu verbessern.
- **Verlustfunktionen & Augmentierung:** Kombiniert Projektionsverlust mit Wiederherstellungsverlust. Driftfreie Segmente werden mit synthetischen Rauschmodellen gestört, um diverse Trainingsbeispiele zu generieren. [13]

Experimente & Ergebnisse

- **Testumgebung:** 6 Sensoreinheiten, jede mit 4 Sensoren, kalibriert gegen hochpräzise Thermometer.
- **Simulierte Daten:** Nichtlineares Sensorfeld mit kontrollierten Drifteinspeisungen.
- **Leistungshighlights:**
 - PRNet stellt doppelt so viele verdriftete Sensoren wieder her wie SPSR-TSBL (80 % Wiederherstellungsrate).
 - Übertrifft SVR-KF (vorhersagebasierter Ansatz) unter rauschigen und nichtlinearen Bedingungen.
 - Generalisiert auf ungesehene Drift-Typen (z.B. Schrittdrift, variierende Rauschpegel). [38]

3.3.3 Mustererkennung

In der Messtechnik verbessert die Mustererkennung durch KI nicht nur die Dateninterpretation, sondern ermöglicht auch Echtzeitüberwachung, prädiktive Diagnosen und intelligente Steuerungsstrategien. Dieser Abschnitt untersucht Schlüsselansätze zur Mustererkennung aus Sensordaten, erforscht repräsentative Architekturen neuronaler Netze und hebt deren Auswirkungen in Branchen wie dem Gesundheitswesen, Automobilsystemen und der Industrieüberwachung hervor.

Computer Vision (CV) und Machine Vision (MV) revolutionieren die Industrieautomation, insbesondere in der Qualitätskontrolle, wo Präzision, Effizienz und Echtzeitleistung entscheidend sind. Mit fortschreitender Industrie 4.0 bietet die Integration von CV mit KI, IoT und Cloud Computing neue Möglichkeiten, stellt aber auch Herausforderungen in Bezug auf Skalierbarkeit und Anpassungsfähigkeit dar. [43]

Schlüsseltechnologien in der industriellen Computer Vision

- **Maschinelles Lernen & Deep Learning:** ML ermöglicht die automatisierte Fehlererkennung durch regelbasierte Klassifikatoren und CNNs. CNNs, die in der

Mustererkennung weit verbreitet sind, ahmen das menschliche Sehen für Aufgaben wie Objektklassifizierung und Fehleridentifikation nach.

- **Farbbasierte Inspektion:** Die industrielle Qualitätskontrolle stützt sich auf RGB-Codierung und hyperspektrale Bildgebung, um Farbinconsistenzen zu erkennen, die oft auf Produktfehler oder Verderb hinweisen.
- **Design von Machine-Vision-Systemen (MVS) [44]:**
 - **Beleuchtung:** Techniken wie polarisierte Beleuchtung verbessern die Bildgebung mit hohem Kontrast.
 - **Bilderfassung:** CMOS- und CCD-Sensoren übersetzen visuelle Daten in messbare Fehlergrößen.
 - **Verarbeitung:** Kantenerkennung, binäre Schwellenwertbildung und Konturanalyse verbessern die Präzision der automatisierten Inspektion.

Industrielle Anwendungen [44]

- **Echtzeit-Qualitätsüberwachung:** Ein robotergestütztes Beton-Drucksystem verwendet Gaußsche Filterung, um Extrusionsfehler zu erkennen, und erreicht dabei Submillimeterpräzision.
- **Bolzen- und Schraubeninspektion mit KI:** Ein CNN-gesteuertes System, das auf Edge-Geräten eingesetzt wird, klassifiziert Fehler mit >95 % Genauigkeit und verwendet Graustufenkonvertierung und Kantenerkennung, um eine automatische Ausschussauslösung zu bewirken.

Zukünftige Richtungen in der Computer Vision für die Industrie [44]

- **Föderiertes Lernen:** Behebt Datenknappheit durch Aggregation verteilter Erkenntnisse unter Wahrung der Privatsphäre.
- **Erklärbare KI (XAI):** Verbessert das Vertrauen in KI-gesteuerte Entscheidungen durch Integration von Aufmerksamkeitskarten für die Interpretierbarkeit.
- **Multimodale Sensorfusion:** Die Kombination von thermischer und Röntgenbildgebung verbessert die Fehlererkennung in komplexen Strukturen.

3.3.4 Anomalieerkennung in Messungen

Im Rahmen der KI in der Messtechnik spielt die Anomalieerkennung eine Schlüsselrolle bei der vorausschauenden Wartung, Qualitätssicherung und Fehlerdiagnose. Dieser Abschnitt untersucht, wie moderne KI-Modelle zur Verbesserung der Anomalieerkennung in sensorbasierten Systemen eingesetzt werden, welche Architekturen am häufigsten angewendet werden und wie diese Methoden die Zuverlässigkeit und Betriebseffizienz in einer Reihe von Branchen verbessern.

Anomalieerkennung ist in Bereichen wie Cybersicherheit, Gerätewartung, Betrugserkennung und Gesundheitsüberwachung von entscheidender Bedeutung, wo die Identifizierung von Abweichungen von erwarteten Mustern die Systemzuverlässigkeit gewährleistet. Trotz ihrer breiten Anwendbarkeit behindern methodische Inkonsistenzen

in der Anomalieerkennungsforschung – wie z.B. unterschiedliche Datenpartitionierungsstrategien, Metrikwahl und Implementierungsdetails – die Reproduzierbarkeit und faire Bewertung. [42]

Herausforderungen bei der Anomalieerkennung

- **Inkonsistente Datenteilung:** Unterschiedliche Partitionierungsmethoden beeinflussen die Modellleistung und Vergleichbarkeit.
- **Metrikvariabilität:** Metriken wie F1-Score, Präzision und Recall hängen von der Schwellenwertauswahl und dem Klassenungleichgewicht ab, was zu inkonsistenten Ergebnissen führt.
- **Implementierungslücken:** Unterschiede in der Datenvorverarbeitung wirken sich erheblich auf die gemeldete Genauigkeit aus.

Standardisierungsbemühungen und Ergebnisse Forscher plädieren für vereinheitlichte Protokolle, einschließlich des ausschließlichen Trainings auf normalen Daten, der Definition von Anomalien als positive Klasse und der Verwendung robuster Metriken wie AUPR für eine verbesserte Anomalieerkennungsempfindlichkeit. Empirische Studien zeigen:

- Neu bewertete Modelle unterscheiden sich oft von früheren veröffentlichten Ergebnissen aufgrund inkonsistenter Bewertung.
- Einfache Modelle wie Vanilla-Autoencoder (DAE) können komplexere Architekturen übertreffen.
- Herausfordernde Datensätze (z.B. CSE-CIC-IDS2018) liefern aussagekräftigere Erkenntnisse als weit verbreitete, aber triviale Datensätze (z.B. KDD).

KI-basierte Anomalieerkennung in drahtlosen Sensornetzwerken (WSNs) WSNs spielen eine wichtige Rolle im Internet der Dinge (IoT), aber Sensoranomalien – verursacht durch Hardwarefehler, Umgebungsveränderungen oder Cyberangriffe – bedrohen die Datenzuverlässigkeit. Traditionelle zentralisierte Anomalieerkennung ist aufgrund hoher Datenübertragungskosten ineffizient, während verteilte Methoden oft unter hoher Rechenkomplexität oder übermäßiger Kommunikation zwischen Sensoren leiden.

Autoencoder-basierte Anomalieerkennung für WSNs Ein dreischichtiger Autoencoder komprimiert und rekonstruiert Sensordaten, um Anomalien auf der Grundlage von Rekonstruktionsfehlern zu erkennen, wobei er ohne gelabelte Daten durch unüberwachtes Lernen arbeitet.

Verteilter Algorithmus-Ansatz

- **Sensor-Ebene (Edge Processing):** Jeder Sensor erkennt Anomalien lokal, indem er Eingabe- und rekonstruierte Werte vergleicht, ohne dass eine Kommunikation zwischen den Sensoren erforderlich ist.

- **Cloud-Ebene-Verarbeitung:** Aggregiert Residuen und aktualisiert globale Statistiken, wobei der Autoencoder regelmäßig neu trainiert wird, um die Genauigkeit zu erhalten und gleichzeitig den Sensor-Overhead zu reduzieren.

Vergleich verschiedener Ansätze zur Anomalieerkennung. [41]

Approach	Data Processing	Advantages	Limitations
Centralized	All sensor data is sent to a central server for anomaly detection.	- High accuracy due to large-scale processing. - Can effectively use deep learning models.	- High bandwidth usage. - Increased latency. - Privacy concerns.
k-NN (k-Nearest Neighbors)	Compares each new data point to its k closest neighbors.	- Simple and interpretable. - Works well with structured data.	- Computationally expensive for large datasets. - Sensitive to noisy data.
Autoencoder (Deep Learning)	Compresses and reconstructs sensor data, detecting anomalies via reconstruction error.	- Works well with high-dimensional data. - Adapts to new data patterns automatically. - Low communication overhead in distributed systems.	- Requires sufficient training data. - Can be difficult to interpret results. - Higher computational complexity compared to traditional methods.