

3 KI in der Messtechnik

Künstliche Intelligenz hat die Messtechnik erheblich verändert, insbesondere durch Computer-Vision-Methoden wie Convolutional Neural Networks. Diese Netzwerke ermöglichen eine präzise Objektllokalisierung innerhalb von Bildern und erleichtern automatisierte Messungen in komplexen Umgebungen. Schlüsselaufgaben wie die Erstellung von Datensätzen, Bildbeschriftung und Datenaugmentation verbessern die Modellgenauigkeit und Widerstandsfähigkeit gegenüber Herausforderungen wie Beleuchtungsinkonsistenzen und Verdeckungen. Fortschrittliche Architekturen wie "You Only Look Once" und "Residual Network" mit Regressionsköpfen werden häufig zur Koordinatenschätzung und Schlüsselpunktdetektion eingesetzt. Über die Objektllokalisierung hinaus verbessert Künstliche Intelligenz Echtzeit-Messsysteme durch Unterdrückung von Signalrauschen, Kalibrierung von Sensoren und Anomalieerkennung, wodurch eine verbesserte Zuverlässigkeit und Betriebseffizienz gewährleistet wird. Industrien nutzen Künstliche Intelligenz für vorausschauende Diagnosen, die Optimierung von Messprozessen und die Rationalisierung von Arbeitsabläufen. Applications of Convolutional Neural Networks span across object localization using YOLO and Faster Region-Based Convolutional Neural Network (Faster R-CNN), as well as Denoising, calibration, and anomaly detection. These technologies, once theoretical, are now integral to smart factories, precision agriculture, transportation, and infrastructure monitoring. [14]

Künstliche Intelligenz hat sich von einem theoretischen Feld zu einer transformativen Kraft in verschiedenen Bereichen entwickelt, angetrieben durch Maschinelles Lernen und dessen Unterfeld, Deep Learning. Neuronale Netze, inspiriert von der Gehirnstruktur, bilden die Grundlage moderner KI-Lösungen. Dieses Kapitel untersucht, wie Convolutional Neural Networks Messtechnologien revolutioniert haben und über konventionelle manuelle Kalibrierung und vordefinierte Modellierung hinausgehen. Deep Learning ermöglicht es Modellen, umfangreiche Datenströme autonom zu verarbeiten, sich dynamisch anzupassen und mit größerer Fehlertoleranz zu arbeiten. Anwendungen von Convolutional Neural Networks umfassen die Objektllokalisierung mittels YOLO und Faster Region-Based Convolutional Neural Network (Faster R-CNN) sowie Entrauschung, Kalibrierung und Anomalieerkennung. Diese Technologien, einst theoretisch, sind heute integraler Bestandteil von Smart Factories, Präzisionslandwirtschaft, Transport und Infrastrukturüberwachung. [17]

3.1 Objektllokalisierung mittels Computer Vision

Die Objektllokalisierung spielt eine entscheidende Rolle in der Assistenztechnologie für sehbehinderte Personen (VIPs). Computer-Vision-basierte Systeme nutzen Tiefenkameras, RGB-Sensoren und Algorithmen des maschinellen Lernens, um Hindernisse zu erkennen und den Benutzern Echtzeit-Feedback zu geben. Die Positionsschätzung ist eine grundlegende Aufgabe in der Messtechnik, da sie Anwendungen in der Robotik, autonomen Navigation, Augmented Reality und Assistenztechnologien für sehbehinderte Personen findet. Traditionelle Methoden

basieren auf Sensorfusion und geometrischen Computer-Vision-Techniken. Diese Ansätze haben jedoch oft Schwierigkeiten in dynamischen Umgebungen aufgrund von Rauschen, Verdeckungen und Rechenkomplexität. Convolutional Neural Networks (CNNs) haben sich als leistungsstarke Alternative erwiesen, die ein End to End Lernen räumlicher Beziehungen aus visuellen Daten ermöglicht. Im Gegensatz zu klassischen Methoden können CNNs Objektpositionen direkt aus Rohbildern vorhersagen, wodurch die Abhängigkeit von handgefertigten Merkmalen reduziert wird. Dieser Abschnitt untersucht, wie CNNs für die Positionsschätzung angewendet werden, wobei der Schwerpunkt auf Architekturdesign, Trainingsmethoden und realen Implementierungen liegt. [30]

Mehrere Studien haben fortgeschrittene Lokalisierungstechniken untersucht:

- **Kinect-Tiefenkameras:** Diese Systeme analysieren Tiefenkarten, um Objektpositionen und -entfernungen zu bestimmen und die Genauigkeit der Hinderniserkennung zu verbessern.
- **Ultraschall- und RGB-Kamera-basierte Systeme:** Geräte integrieren Ultraschallsensoren mit RGB-Kameras, um die Lokalisierungspräzision zu verbessern und Feedback über Audio- oder haptische Signale zu geben.
- **Algorithmen des maschinellen Lernens:** Ansätze wie CNN, YOLO (You Only Look Once) und SVM (Support Vector Machine) wurden verwendet, um die Objekterkennung und das räumliche Bewusstsein zu verbessern. Diese Systeme erzeugen 3D-Darstellungen der Umgebung und verbessern so die Fähigkeit des Benutzers, sich sicher zu navigieren.
- **Tragbare Systeme:** Einige Assistenztechnologien integrieren Smart Glasses, mobile Apps oder am Kopf getragene Geräte mit Deep-Learning-Modellen, um Hindernisse zu erkennen und zu lokalisieren. Diese Systeme erreichen hohe Genauigkeitsraten und helfen VIPs, Kollisionen in dynamischen Umgebungen zu vermeiden.
- **Semantische Objekterkennung & Tiefenkarten:** Durch die Kombination von Objekterkennung mit Tiefenschätzung ermöglichen einige Lösungen Benutzern, zwischen verschiedenen Arten von Hindernissen zu unterscheiden und deren Nähe in Echtzeit zu beurteilen. [26]

Assistive Technologien für sehbehinderte Menschen lassen sich in drei Hauptkategorieinteilen: **Objekterkennungsgeräte**, **Navigationssysteme** und **Hybridgeräte**, die beide Funktionen kombinieren. Diese Systeme vermitteln Informationen durch Ton oder Vibration und unterstützen Nutzer dabei, Hindernisse zu erkennen und sich sicher in ihrer Umgebung zu bewegen.

Objekterkennungsgeräte

Diese Geräte nutzen Sensoren, Ultraschallsysteme oder Kameras, um Umgebungsdaten zu erfassen und dem Nutzer Feedback zu geben [37]:

- **Kinect-Tiefenkameras und Ultraschallstöcke** erkennen Hindernisse und berechnen deren Entfernung mithilfe adaptiver Schwellenwerte oder Schallwellen.
- **Multisensorsysteme** setzen maschinelles Lernen (z. B. SVM, CNN) zur Objekterkennung ein und liefern akustisches oder haptisches Feedback.
- **Tragbare Lösungen** wie Brillen oder Smartphone-basierte Deep-Learning-Modelle erreichen eine hohe Genauigkeit bei der Hinderniserkennung.

Navigationssysteme

Navigationshilfen leiten VIPs mithilfe von **GPS, RFID und AR-Technologien**:

- **Geräte mit RGB-D-Sensoren** unterstützen Nutzer durch Tiefen- und Farbinformationen.
- **Einige Wearables** nutzen Sprachausgabe, haptische Signale oder Audiodaten für Echtzeitführung.
- **Bildgestützte Systeme** helfen beim Joggen, Laufen und Gehen, z. B. durch Handschuhe mit Bewegungserkennung [33].

Hybridsysteme

Diese kombinieren Objekterkennung und Navigation für eine verbesserte Mobilität:

- **Intelligente Blindenstöcke, kopfbasiertes Equipment und mobile Apps** erkennen Hindernisse und unterstützen gleichzeitig die Wegführung.
- **KI-gestützte Lösungen** (z. B. YOLO-basierte Erkennung und Echtzeit-Segmentierung) identifizieren komplexe Hindernisse wie Wände oder Türen mit hoher Präzision.
- **Einige Systeme** nutzen elektrotaktilen Feedback, z. B. durch Zungenstimulation, um die Navigation zu erleichtern [39].

3.1.1 Anwendung von Convolutional Neural Networks (CNNs) zur Positionsschätzung

CNNs sind zu einem leistungstarken Werkzeug für die Positionsschätzung geworden, insbesondere in Anwendungen, die eine präzise Objektlokalisierung und -verfolgung erfordern. Ihre Fähigkeit, räumliche Merkmale aus Bildern und Sensordaten zu extrahieren, macht sie in der Robotik, autonomen Navigation und industriellen Automatisierung hochwirksam. [32]

Die Positionsschätzung beinhaltet die Bestimmung der räumlichen Koordinaten oder der Orientierung von Objekten in Bildern oder Sensordaten. CNNs werden für diese Aufgabe aufgrund ihrer Fähigkeit, hierarchische Merkmale aus Rohdaten zu lernen, weit verbreitet eingesetzt. Nachfolgend finden Sie eine Aufschlüsselung, wie CNNs in diesem Bereich angewendet werden, zusammen mit Schlüsselarchitekturen und Herausforderungen. [38]

Wie CNNs die Positionsschätzung ermöglichen

CNNs verarbeiten visuelle und Sensordaten, um die Position eines Objekts zu schätzen, indem sie:

- **Merkmalextraktion:** Schlüsselmuster in Bildern oder Sensorinputs identifizieren.
- **Tiefen- & Raumwahrnehmung:** Mehrschichtige Architekturen zur Analyse von Objektabständen und -orientierungen nutzen.
- **Echtzeitanpassung:** Positionsschätzungen kontinuierlich auf der Grundlage von Umweltveränderungen verfeinern.

Anwendungen von CNNs in der Positionsschätzung

- **Robotik & Steuerung:** CNNs helfen selbstfahrenden Autos, Fahrspurpositionen, Hindernisse und Fußgänger zu erkennen. In der Robotik ermöglichen CNN-basierte Vision-Systeme eine präzise Objektmanipulation und Navigation. CNNs werden in der Robotik häufig für Lokalisierung und autonome Bewegung eingesetzt. Sie helfen bei der Schätzung der Position von Objekten für Roboterarme, was eine präzise Manipulation in der Industrieautomation und Gesundheitsrobotik ermöglicht.
- **Cybersicherheit:** CNNs können helfen, positionsbasiertes Verhalten in Cybersicherheitssystemen zu schätzen, indem sie Anomalien in der Netzwerkaktivität verfolgen und bösartige Zugangspunkte erkennen. Zum Beispiel analysieren Deep-Learning-Modelle Muster in Cyberangriffen, um deren Ursprung und Position innerhalb eines Systems zu bestimmen und so Intrusionen zu verhindern. Sie unterstützen die Lagerautomatisierung, indem sie Roboter an bestimmte Orte führen.
- **Medizinische Informationsverarbeitung:** CNNs verbessern die Positionsverfolgung in der Roboterchirurgie und gewährleisten Präzision. Sie helfen bei der MRT- und CT-Ausrichtung, verbessern die diagnostische

Genauigkeit, indem sie die Position von Anomalien in Röntgen-, MRT- und CT-Bildern bestimmen. Sie unterstützen die Roboterchirurgie, indem sie chirurgische Instrumente mit hoher Präzision verfolgen.

- **Natural Language Processing (NLP):** CNNs können bei der Positionsschätzung von Schlüsselwörtern oder -phrasen innerhalb großer Datensätze helfen. Zum Beispiel helfen CNNs, ortsbezogene Informationen aus Textdaten zu extrahieren, was Anwendungen wie die geospatialen Analysen für die Smart-City-Entwicklung verbessert.

3.1.2 Vorverarbeitungsschritte: Datensatzerstellung, Bildbeschriftung, Augmentierung

Die Vorverarbeitung ist eine kritische Phase bei der Entwicklung robuster Computer-Vision-Modelle, insbesondere für Aufgaben wie Bildklassifizierung, Objekterkennung oder Segmentierung. Dieser Abschnitt befasst sich mit drei wichtigen Vorverarbeitungsschritten: Datensatzerstellung, Bildbeschriftung und Datenaugmentation, die zusammen eine qualitativ hochwertige Eingabedaten für das Training von Deep-Learning-Modellen gewährleisten.

1. Datensatzerstellung Die Datensatzerstellung umfasst das Sammeln und Organisieren von Bildern, die für das Problemfeld relevant sind. Wichtige Überlegungen sind:

- **Datenquellen:**
 - Öffentliche Datensätze (z. B. ImageNet, COCO, CIFAR-10).
 - Benutzerdefinierte Datensätze (z. B. Web-Scraping, manuelle Sammlung oder synthetische Datengenerierung). [20]
- **Diversität und Repräsentativität:**
 - Sicherstellen, dass der Datensatz Variationen in Beleuchtung, Winkeln, Hintergründen und Objektskalen abdeckt, um Verzerrungen zu vermeiden.
 - Für die medizinische Bildgebung müssen Datensätze seltene Fälle enthalten, um die Generalisierbarkeit des Modells zu verbessern. [29]
- **Strukturierte Speicherung:**
 - Bilder in Ordnern organisieren (z. B. klassenweise für Klassifizierungsaufgaben).
 - Standardisierte Formate (JPEG, PNG) und Auflösungen (z. B. 256x256 für Konsistenz) verwenden. [20]

2. Bildbeschriftung

Die Beschriftung weist Bildern sinnvolle Anmerkungen zu und ermöglicht uns ein überwachtes Lernen. In einer 2022 veröffentlichten Studie hat ein Forscherteam ein schwach überwachtes Convolutional Neural Network (CNN) zur Objektklassifizierung entwickelt, das während des Trainings nur Labels auf Bildebene (die das Vorhandensein oder Fehlen eines Objekts angeben) verwendet und dennoch in der Lage ist, aus überladenen Szenen mit mehreren Objekten zu lernen. Die Leistung des Modells wird an zwei Benchmark-Datensätzen bewertet: Pascal VOC 2012 (20 Objektklassen) und dem deutlich größeren Microsoft COCO (80 Objektklassen). Die Analyse zeigt, dass das Netzwerk Folgendes konnte:

- Erreicht hohe Genauigkeit bei der Vorhersage von Labels auf Bildebene.
- Lokalisiert Objekte ungefähr (aber nicht deren präzise Ausdehnung).
- Erreicht eine Leistung, die mit vollständig überwachten Gegenständen vergleichbar ist, die mit Bounding-Box-Annotationen trainiert wurden.

Bemerkenswert ist, dass das Netzwerk lernt, Objekte ohne jegliche räumliche Überwachung (z. B. Bounding Boxes oder Segmentierungsmasken) während des Trainings zu lokalisieren, indem es sich ausschließlich auf binäre Objekt-Präsenz-Labels stützt. Darüber hinaus werden Objekte mit typischerem Aussehen (z. B. Motorräder, wie in der linken Spalte gezeigt) im Trainingsprozess früher lokalisiert als solche mit größerer Variabilität innerhalb der Klasse. [35]




Abb 3.1 Links: MNIST-Ziffernbeispiele. Mitte-links: Drei Faltungskerne (tatsächliche Größe und vergrößert; mittelgrau=0, hell=positiv, dunkel=negativ). Mitte-rechts: Kernreaktionen auf Ziffern angewendet. Rechts: Schwellenwerte der Aktivierungen (grün=positiv, rot=negativ). Die Kerne fungieren als (von oben nach unten): ein

horizontaler Balkendetektor, ein vertikaler Balkendetektor und ein Linienendendetektor, empfindlich gegenüber der Kontrastpolarität. Obwohl effektiv, bleibt ihre Lokalisierung unvollkommen. Aus S. Russell und P. Norvig, Artificial Intelligence: A Modern Approach, 4th ed., 2021. [19]

CNNs zeichnen sich bei der Bildklassifizierung durch ihre Fähigkeit aus, hierarchische Merkmalsdarstellungen direkt aus Pixeldaten zu lernen. Um zu verstehen, warum CNNs gut funktionieren, ist es lehrreich, Bilddatensätze wie MNIST zu untersuchen, einen Standard-Benchmark, der aus 70.000 handgeschriebenen Ziffern (0–9) besteht. Die Analyse dieses Datensatzes zeigt zwei Schlüsseleigenschaften von Bildern:

1. **Invarianz gegenüber lokalen Störungen:** Kleine Transformationen (z. B. Translation, Rotation, Helligkeitsänderungen) verändern die semantische Bedeutung eines Bildes nicht. Zum Beispiel bleibt eine Ziffer "8" erkennbar, auch wenn sie leicht verschoben wird, was impliziert, dass genaue Pixelpositionen weniger kritisch sind als strukturelle Muster.
2. **Lokale und hierarchische Merkmalsbedeutung:** Diskriminierende Merkmale ergeben sich oft aus lokalisierten Mustern und ihren räumlichen Beziehungen.

Praktische Verbesserungen und Herausforderungen Obwohl CNNs ohne umfangreiche Abstimmung eine starke Leistung erzielen können, verbessern verschiedene Techniken die Robustheit weiter:

- **Datenaugmentation:** Die künstliche Erweiterung des Trainingsdatensatzes mit gestörten Kopien reduziert Overfitting und verbessert die Generalisierung. Testzeit-Augmentierung kann auch die Vorhersagestabilität verbessern.
- **Kontextuelles Lernen:** CNNs lernen implizit, diskriminierende Regionen zu priorisieren, selbst wenn Objekte nur einen Bruchteil der Pixel einnehmen. Kontextuelle Hinweise können die Erkennung unterstützen, obwohl ihr Nutzen von den Datenspezifika abhängt.[19]

3. Datenaugmentation

Datenaugmentation erweitert den Datensatz künstlich durch Anwenden von Transformationen auf vorhandene Bilder, wodurch die Modellrobustheit verbessert und Overfitting reduziert wird. Techniken umfassen:

A. Grundlegende Augmentierungen

- **Geometrische Transformationen:**
 - Rotation: Bilder um 10° – 30° drehen.
 - Spiegelung: Horizontale/vertikale Spiegelungen.
 - Zuschneiden/Translation: Zufällige Ausschnitte oder Verschiebungen.
- **Photometrische Transformationen:**

- Helligkeit/Kontrast: Beleuchtungsbedingungen anpassen.
- Farbjittering: RGB-Kanäle stören.
- Rauschinjektion: Gaußsches Rauschen hinzufügen, um Sensorartefakte zu simulieren.

B. Fortgeschrittene Augmentierungen

- **Zufälliges Löschen (Random Erasing):** Zufällige Bereiche maskieren, um den Fokus auf ganze Objekte zu erzwingen.
- **Mixup:** Zwei Bilder linear mischen.
- **GAN-basierte Augmentierung:**
 - Generieren synthetischer Bilder.
 - Stiltransfer.
- **Meta-Learning Augmentierungen:**
 - Verwenden von Reinforcement Learning, um optimale Augmentierungsstrategien zu entdecken.

Datenaugmentation im maschinellen Lernen Die synthetische Generierung von gelabelten Daten deutet darauf hin, dass dies durch die Nutzung inhärenter statistischer Symmetrien in den Daten geschieht. Viele Anwendungen des maschinellen Lernens umfassen Datensätze, die, zumindest annähernd, intrinsische Symmetrien und Invarianzen aufweisen. Zum Beispiel bleibt ein gedrehtes Bild einer handgeschriebenen Zahl als diese Zahl erkennbar, und eine an einem bestimmten Ort aufgenommene Temperaturmessung wird einer nur wenige Augenblicke später vorgenommenen Messung sehr ähnlich sein. Datenaugmentation nutzt solche Symmetrien und Invarianzen, um Rohdatensätze durch die Einführung zusätzlicher synthetischer Daten zu erweitern. [41]

Gegeben sei ein Rohdatensatz: $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$

Der entsprechende augmentierte Datensatz wird bezeichnet als:

$$D_0 = \{(x_{\{11\}}, y_1), (x_{\{12\}}, y_1), \dots, (x_{\{mB\}}, y_m)\}$$

Wobei $m_0 = B \times m$ die Gesamtgröße des augmentierten Datensatzes darstellt.

Und wenn empirische Risikominimierungs (ERM)-Methoden verwendet werden, tritt häufig Overfitting auf, wenn die Dimensionalität des Hypothesenraums die Anzahl der Trainingsbeispiele übersteigt. Regularisierung und Modellauswahl mildern dieses Problem, indem sie den Hypothesenraum einschränken. Ein alternativer Ansatz ist die Datenaugmentation, bei der der Trainingsdatensatz synthetisch erweitert wird, indem inhärente Datensymmetrien genutzt werden – zum Beispiel bleibt ein gedrehtes Bild einer Katze eine gültige Darstellung einer Katze. [36]

Datenaugmentation dient als implizite Regularisierungstechnik, wobei die Störverteilung $p(\epsilon)$ den Regularisierungseffekt bestimmt. Dieser Ansatz ermöglicht es, den Bias-

Varianz-Kompromiss ohne explizite Strafterme auszugleichen, was ihn besonders in Szenarien mit wenig Daten wertvoll macht. [26]

3.1.3 Modelle für die Koordinatenregression

Die Koordinatenregression beinhaltet die Vorhersage kontinuierlicher numerischer Werte (Koordinaten) aus Eingabedaten. Die Koordinatenregression ist also der Prozess der Vorhersage präziser räumlicher Koordinaten aus einer gegebenen Eingabe, anstatt Objekte in Kategorien zu klassifizieren. Bei Computer-Vision-Aufgaben ist die Koordinatenregression für Anwendungen wie menschliche Haltungsschätzung, Objekterkennung und -verfolgung unerlässlich. Traditionelle CNN-Architekturen verlassen sich oft auf Heatmap-basierte Methoden für räumliche Aufgaben, aber DSNT führt einen direkteren Ansatz für die Koordinatenregression ein, während räumliche Generalisierbarkeit und End-to-End-Differenzierbarkeit erhalten bleiben. [37]

Problemdefinition Die Haltungsschätzung für mehrere Personen zielt darauf ab, anatomische Schlüsselpunkte für alle Personen in einem Bild zu identifizieren. Jede Haltung wird durch K 2D-Schlüsselpunkte dargestellt.

Entkoppelte Schlüsselpunktregression (DEKR) Das DEKR-Framework sagt Haltungskandidaten an jedem zentralen Pixel q voraus, indem es einen $2K$ -dimensionalen Offsetvektor o_q schätzt, der q auf die K Schlüsselpunkte abbildet. Offset-Karten O werden über eine Regressionsfunktion F generiert: $O=F(X)$, wobei X Backbone-Merkmale darstellt (HRNet in dieser Studie).




Abb 3.2 Diese Abbildung veranschaulicht den DEKR-Prozess, bei dem jeder Schlüsselpunkt separat über einen dedizierten Zweig gelernt wird. Jeder Zweig extrahiert Merkmale mithilfe von zwei adaptiven Faltungen und sagt dann den 2D-Offset für seinen entsprechenden Schlüsselpunkt mithilfe einer 1×1 -Faltung voraus. Basierend auf der Studie *Bottom-Up Human Pose Estimation Via Disentangled Keypoint Regression* (2021). [46]

Schlüsselinnovationen

- **Adaptive Faltungen:** Im Gegensatz zu Standardfaltungen passen adaptive Faltungen die rezeptiven Felder dynamisch an, um sich auf Schlüsselpunktregionen zu konzentrieren. Für ein zentrales Pixel q wird die Aktivierung $y(q)$ berechnet als: $y(q) = \sum Wix(q + g_{\{s_i\}}^q)$, wobei $g_{\{s_i\}}^q$ gelernte Offsets sind, die aus einer affinen Transformation Aq und Translation t abgeleitet werden, was eine pixelweise räumliche Anpassung ermöglicht.
- **Mehrzweig-Regression:** DEKR verwendet K parallele Zweige, von denen jeder eine dedizierte Merkmalskarte X_k verarbeitet, um Offsets für den k -ten Schlüsselpunkt vorherzusagen: $O_k = F_k(X_k)$, für $k=1, \dots, K$. Dies entkoppelt das Merkmalenlernen und verbessert die Lokalisierungsgenauigkeit. [46]

Verlustfunktionen

- **Regressionsverlust:** Der Smooth L1-Verlust bestraft Offset-Fehler, normalisiert durch die Instanzgröße Z_i : $\ell_p = \sum \left(\frac{1}{Z_i}\right) \text{smoot}\{L_1\}(o_i - o_k)$
- **Heatmap-Verlust:** Ein separater Zweig sagt Schlüsselpunkt-Heatmaps H und Zentrum-Heatmaps C voraus, die mittels maskiertem L2-Verlust überwacht werden $\ell_h = \|M_h \odot (H - H^*)\|^2 + \|M_c \odot (C - C^*)\|^2$. Hier gewichten M_h und M_c Nicht-Schlüsselpunktregionen herunter.
- **Gesamtverlust:** $\ell = \ell_h + \lambda \ell_p$, wobei $\lambda=0.03$. [51]

Vorteile

- **Präzision:** Die Mehrzweig-Regression minimiert Interferenzen zwischen Schlüsselpunkten.
- **Flexibilität:** Adaptive Faltungen verbessern den Fokus auf Schlüsselpunktregionen. [46]

3.1.4 Robustheitsüberlegungen: Beleuchtung, Verdeckung, Echtzeit-Feedback

In einer Studie über CNN-Varianten untersuchten Forscher Beleuchtungsüberlegungen und betonten die Bedeutung der Beleuchtung in maschinellen Visionssystemen. Sie hoben hervor, dass "Beleuchtung das zu inspizierende Teil so beleuchtet, dass seine Merkmale hervorstechen und von der Kamera präzise gesehen werden können", und diskutierten verschiedene Beleuchtungsaufbauten wie Front- und Hintergrundbeleuchtung zur Verbesserung der Objektsichtbarkeit. [38] Verschiedene Lichtquellen, darunter Glühlampen, Leuchtstofflampen, Laser, Röntgenröhren und Infrarotlichter, wurden als wesentlich für die Verbesserung der Bildqualität bei der industriellen Inspektion genannt. [44]

Die Herausforderungen, denen Gesichtserkennungssysteme gegenüberstehen, betonen die Notwendigkeit, Variationen in der Beleuchtung, Haltungsänderungen und Gesichtsausdrücke zu berücksichtigen. Diese Faktoren beeinflussen die Modellleistung

erheblich und erfordern fortschrittliche Techniken wie tiefe Convolutional Neural Networks, um die Robustheit zu verbessern. Studien haben Methoden wie Multitasking-kaskadierte CNNs und adaptive Vorverarbeitung vorgeschlagen, um die Erkennungsgenauigkeit unter verschiedenen Bedingungen zu verbessern. [46]

Zur Handhabung von Verdeckungen diskutierte die Studie Deep Learning (DL) und Convolutional Neural Networks (CNNs) als kritische Werkzeuge in modernen Computer-Vision-Techniken. Obwohl Verdeckungsprobleme nicht explizit detailliert wurden, verwies die Forschung auf fortgeschrittene KI-Modelle, die visuelle Daten unter verschiedenen Bedingungen verarbeiten und eine zuverlässige Bilderkennung ermöglichen, selbst wenn bestimmte Merkmale teilweise verdeckt sind. [44]

In einer anderen Studie untersuchten Forscher die Verdeckungsbehandlung in Haltungsschätzungsmodellen. Sie stellten fest, dass "die Behandlung des Verdeckungsproblems" eine kritische Herausforderung bei der Haltungsschätzung mehrerer Personen ist und verwiesen auf mehrere Ansätze zur Verbesserung der Leistung unter Bedingungen teilweiser Sichtbarkeit. Die Studie diskutierte Methoden wie Verbesserungen der Schlüsselpunktlokalisierung, Multi-Task-Lernarchitekturen und Gruppierungstechniken zur Assoziation von Schlüsselpunkten, die zu derselben Person gehören, was dazu beiträgt, die Auswirkungen der Verdeckung zu mindern. [46]

Hinsichtlich des Echtzeit-Feedbacks untersuchte die Studie die Rolle von Machine Vision (MV)-Systemen, d.h. Systemen, die KI-gesteuerte Bildverarbeitung für die Echtzeit-Visualisierung verwenden, um eine sofortige und automatisierte Inspektion in Hochgeschwindigkeits-Produktionslinien zu gewährleisten. Es wurde festgestellt, dass "MV sich bei der quantitativen Messung einer strukturierten Szene aufgrund ihrer Geschwindigkeit, Genauigkeit und Wiederholbarkeit auszeichnet", was eine effiziente Qualitätskontrolle in Fertigungsanwendungen ermöglicht. [44]

3.1.5 Beispielarchitekturen

Convolutional Neural Networks (CNNs) sind ein entscheidendes KI-Werkzeug für Computer Vision (CV)-Aufgaben, die sich durch Objekterkennung, Klassifizierung und Segmentierung auszeichnen. Ihr Erfolg hängt von großen gelabelten Datensätzen ab, was sie in Anwendungen wie der Verkehrszeichenerkennung, medizinischen Bildgebung, Gesichtserkennung und Objekterkennung hochwirksam macht.

Schlüsselanwendungen in Computer Vision

- **Gesichtserkennung:** CNNs bewältigen Herausforderungen wie Beleuchtungsvariationen und Verdeckungen. Methoden wie tiefe CNNs (Farfadi et al., 2015) und Multitask-kaskadierte CNNs (Zhang et al., 2016) haben die Genauigkeit verbessert.

- **Menschliche Haltungsschätzung:** CNN-Architekturen verfeinern Körper-Heatmaps mittels Regressionstechniken (Bulat & Tzimiropoulos, 2016).
- **Aktionserkennung:** Traditionell auf Bewegungshistoriebilder und HMMs angewiesen, übertreffen 3D-CNNs in Kombination mit LSTMs (Wang et al., 2017) nun frühere Ansätze. [60]

Breitere KI-Anwendungen CNNs erstrecken sich über Computer Vision hinaus in die Bereiche der natürlichen Sprachverarbeitung, Objekterkennung, Spracherkennung, Videoanalyse und mehrdimensionale Dateninterpretation, was ihre Vielseitigkeit in der modernen KI-Forschung demonstriert.

Ein Beispiel für eine Architektur ist YOLO (You Only Look Once), ein weit verbreitetes Objekterkennungsframework, das Bounding Boxes vorhersagt und Objekte in vordefinierte Kategorien klassifiziert. YOLO ist ein Echtzeit-Objekterkennungsmodell, das auf CNNs basiert. Es verarbeitet ein gesamtes Bild auf einmal und identifiziert mehrere Objekte effizient. Standard-YOLO fehlt jedoch die Fähigkeit, Objektabstände von der Kamera zu schätzen. Um diese Einschränkung zu beheben, hat ein Forscherteam Dist-YOLO verwendet, eine verbesserte Version, die die Abstandsschätzung integriert, während die ursprünglichen YOLO-Erkennungsfähigkeiten beibehalten werden. [35]




Abb 3.3 Die YOLO-Architektur wird modifiziert, um die Entfernung von Objekten zu schätzen, basierend auf der Studie *Dist-YOLO: Fast Object Detection with Distance Estimation* (M, 2022). [35]

Der Ansatz erweitert die von den YOLO-Erkennungsköpfen generierten Vorhersagevektoren um Entfernungsinformationen und integriert eine spezielle Entfernungsverlustfunktion während des Trainings. Experimentelle Ergebnisse zeigen, dass Dist-YOLO nicht nur die ursprüngliche Kapazität des Backbone-Netzwerks beibehält, sondern auch die Genauigkeit der Bounding-Box-Erkennung im Vergleich zum YOLO-Basismodell verbessert. Darüber hinaus bietet Dist-YOLO in Verbindung mit einer monokularen Kamera eine präzise Abstandsschätzung für erkannte Objekte, was seine Anwendbarkeit in realen Szenarien erheblich erweitert. [35]

Im Gegensatz zu herkömmlichen zweistufigen Detektoren wie R-CNN formuliert YOLO die Objekterkennung als einstufiges Regressionsproblem um, so dass das Modell die

Bounding Boxes und Klassenwahrscheinlichkeiten direkt aus einem Bild in einem Durchgang vorhersagen kann. Diese Designentscheidung führt zu extrem schnellen Schlussfolgerungen, was es ideal für zeitkritische Anwendungen wie Videoüberwachung, autonomes Fahren und Robotik macht. [47]




Abb. 3.4 Netzwerkarchitektur von YOLOv4.basierend auf der Studie Anwendung von verschiedenen YOLO Models for Computer Vision-Based Real-Time Pothole Detection (2021). [47]

Key Improvements Across YOLO Versions

- **YOLOv1-v3**: Introduced multi-scale **feature pyramids (FPN)**, an optimized **Darknet53 backbone**, and binary cross-entropy loss for classification.
- **YOLOv4**: Enhanced the framework with a **three-component structure** (backbone, neck, head) and advanced **optimization techniques** ("bag of freebies"). Achieved high accuracy (43.5% AP on MS COCO) with real-time performance (65 FPS on Tesla V100).
- **YOLOv4-tiny**: A lightweight version using **CSPDarknet53-tiny**, optimized for low-resource environments.
- **YOLOv5**: Improved **network efficiency**, **streamlined architecture**, and **PyTorch-based implementation**. It retained YOLOv4's accuracy while enhancing deployment with YOLOv5 offering enhanced accuracy and speed. [28]

Eine andere Studie konzentrierte sich auf die Annäherung nichtlinearer Funktionen mit Hilfe fortschrittlicher neuronaler Architekturen, insbesondere residualer neuronaler Netze (ResNet), die für nichtlineare Regression und nicht für bildbasierte Aufgaben angepasst

wurden. Der methodische Kern passt die ResNet-Prinzipien an die nichtlineare Regression an, indem er Faltungsschichten durch vollständig verbundene Blöcke ersetzt (Abb 2). Diese Anpassung geht auf die Dimensionsbeschränkungen traditioneller ResNet-Architekturen bei der Verarbeitung von Vektoreingaben anstelle von Bilddaten ein. [61]

Einige der wichtigsten Änderungen sind:

1. **Architektonische Anpassung:** Umwandlung von Restblöcken in dichte Schichten unter Beibehaltung der Stapelnormalisierung zur Regularisierung.
2. **Dimensionale Handhabung:** Identitätsblöcke (Tafel a) für dimensionserhaltende Flüsse und dichte Blöcke (Tafel b) für dimensionsverschiebende Operationen.
3. **Rechnerische Optimierung:** Eliminierung lokaler Faltungsoperatoren zugunsten globaler dichter Verbindungen. [62]

Die empirische Validierung nutzt synthetisch generierte Datensätze (Gleichungen 2–5) mit **10^7 Stichproben pro Funktionsklasse**, aufgeteilt in:

- Trainingsdaten: $6,75 \times 10^6$
- Validierungsdaten: $7,5 \times 10^5$
- Testdaten: $2,5 \times 10^6$

Die optimale Konfiguration mit 28 Schichten und einer Breite von 16 erreicht eine außergewöhnliche Leistung (Testverluste zwischen $2,55 \times 10^{-5}$ und $4,21 \times 10^{-4}$) und übertrifft deutlich:

- **Lineare Methoden** ($R^2 < 0,5$ in allen Fällen)
- **Klassische nichtlineare Ansätze** (z. B. SVR mit Trainingszeiten > 12 Stunden)
- **Standard-Neuronale Netze** (20–30 % höhere Validierungsverluste)

Wie in **Tabelle 5** quantifiziert, zeigen visuelle Vergleiche (**Abbildung 5**) eine präzise Übereinstimmung zwischen Vorhersagen und Grundwahrheit über verschiedene Funktionskomplexitäten hinweg [62].

3.1.6 Signale zur Anomalieerkennung

Im Zeitalter des Internet der Dinge (IoT) und der zunehmenden Komplexität von Netzwerken ist die Anomalieerkennung für die Gewährleistung der Datensicherheit und der Zuverlässigkeit von Systemen von entscheidender Bedeutung. Künstliche Intelligenz spielt eine zentrale Rolle bei der Identifizierung ungewöhnlicher Muster, die auf Bedrohungen, Fehler oder Fehlfunktionen hinweisen könnten. Dieser Abschnitt befasst sich mit der Anwendung von KI in der Anomalieerkennung und hebt bestimmte Herausforderungen und Ansätze hervor.

3.1.6.1 Herausforderungen in der KI-basierten Anomalieerkennung

Trotz der Fortschritte bei KI-basierten Methoden zur Anomalieerkennung bleiben erhebliche Herausforderungen bestehen, insbesondere in komplexen Systemen wie drahtlosen Sensornetzwerken (WSNs) und heterogenen Datensätzen.

- **Hohe Dimension und Datenvolumen:** Moderne Netzwerke generieren riesige Datenmengen mit vielen Merkmalen, was das Training von Anomalieerkennungsmodellen rechenintensiv und speicherintensiv macht.
- **Mangel an gelabelten Anomaliendaten:** Echte Anomalien sind selten und schwer zu labeln, was überwachte Lernansätze behindert. Dies erfordert den Einsatz von unüberwachten oder semi-überwachten Methoden.
- **Konzeptdrift:** Das Verhalten von Anomalien kann sich im Laufe der Zeit ändern, was dazu führt, dass trainierte Modelle veraltet werden und eine kontinuierliche Anpassung erfordern.
- **Rauschen und irrelevanten Merkmalen:** Daten enthalten oft Rauschen und irrelevante Merkmale, die die Leistung von Anomalieerkennungsalgorithmen mindern.
- **Rechenbeschränkungen am Edge:** In WSNs und IoT-Geräten mit begrenzten Rechenressourcen ist es schwierig, komplexe Anomalieerkennungsalgorithmen direkt am Sensor (Edge Processing) zu implementieren.

Eine 2023 veröffentlichte Studie, die verschiedene Methoden zur Anomalieerkennung in WSNs vergleicht, beleuchtet diese Herausforderungen. Die Forscher kamen zu dem Schluss, dass die Neubewertung bestehender Modelle entscheidend ist, da veröffentlichte Ergebnisse oft aufgrund inkonsistenter Bewertungsmetriken oder Datensätze variieren. Sie fanden heraus, dass einfache Modelle wie Vanilla-Autoencoder (DAE) komplexere Architekturen übertreffen können, wenn sie auf herausfordernden Datensätzen wie CSE-CIC-IDS2018 trainiert werden, die aussagekräftigere Einblicke bieten als weit verbreitete, aber triviale Datensätze wie KDD. Darüber hinaus betonen sie die Notwendigkeit robuster Modelle zur Anomalieerkennung in WSNs angesichts von Bedrohungen wie Hardwarefehlern, Umweltveränderungen oder Cyberangriffen. [60]

3.1.6.2 KI-basierte Anomalieerkennung in drahtlosen Sensornetzwerken (WSNs)

Drahtlose Sensornetzwerke (WSNs) spielen eine entscheidende Rolle im Internet der Dinge (IoT), aber Sensoranomalien – verursacht durch Hardwarefehler, Umweltveränderungen oder Cyberangriffe – bedrohen die Datenzuverlässigkeit. Traditionelle zentralisierte Anomalieerkennung ist aufgrund hoher Datenübertragungskosten ineffizient, während verteilte Methoden oft unter hoher Rechenkomplexität oder übermäßiger Kommunikation zwischen Sensoren leiden.

Autoencoder-basierte Anomalieerkennung für WSNs Ein dreischichtiger Autoencoder komprimiert und rekonstruiert Sensordaten, um Anomalien auf der Grundlage von Rekonstruktionsfehlern zu erkennen, wobei er ohne gelabelte Daten durch unüberwachtes Lernen arbeitet. [62]

Verteilter Algorithmus-Ansatz

- **Sensor-Ebene (Edge Processing):** Jeder Sensor erkennt Anomalien lokal durch Vergleich von Eingabe- und rekonstruierten Werten, was keine Kommunikation zwischen Sensoren erfordert.
- **Cloud-Ebene-Verarbeitung:** Aggregiert Residuen und aktualisiert globale Statistiken, wobei der Autoencoder regelmäßig neu trainiert wird, um die Genauigkeit zu erhalten und gleichzeitig den Sensor-Overhead zu reduzieren.

Vergleich verschiedener Ansätze zur Anomalieerkennung. [41]

3.2 Weitere wichtige Anwendungen

Moderne Messsysteme nutzen zunehmend Künstliche Intelligenz, um traditionelle Einschränkungen bei der Datenqualität, Sensorempfindlichkeit und Betriebsüberwachung zu überwinden. Über die grundlegenden Anwendungen in der Objektlokalisierung und Regressionsmodellierung hinaus bieten KI-gesteuerte Techniken nun transformative Verbesserungen in vielen kritischen Bereichen. Über die Objektlokalisierung und Regressionsmodelle hinaus bieten KI-gesteuerte Messtechnologien robuste Verbesserungen bei der Datenverarbeitung, Systemgenauigkeit und prädiktiven Zuverlässigkeit. Diese Fortschritte betreffen die Signalintegrität, Sensorleistung und Anomalieerkennung und gewährleisten präzise und adaptive Reaktionen in verschiedenen Branchen. Von der Unterdrückung von Signalrauschen bis zur Sensorkalibrierung mittels Deep Learning verfeinert KI Messtechniken, indem sie komplexe Muster erkennt und Fehler vorhersagt, bevor diese die Systemleistung beeinträchtigen. [49]

Praktische Anwendungen von CNN-basierter Lokalisierung umfassen Roboterarme, die Objekte auf Förderbändern erkennen und greifen [33], Drohnen, die Flugrouten basierend auf YOLO-abgeleiteten Orientierungspunkten anpassen, und intelligente Fabriken, die Teile und Defekte mit Hochgeschwindigkeitskameras und eingebetteten Bildverarbeitungsprozessoren verfolgen [38].

3.2.1 Signalrauschunterdrückung

Deep-Learning-Architekturen trennen effektiv sinnvolle Signale von Rauschen in Umgebungen mit niedrigen Signal-Rausch-Verhältnissen. Anwendungen mit hohem Rauschen umfassen die Vibrationsanalyse in der vorausschauenden Wartung, wo rekurrente neuronale Netze eine Rauschunterdrückung von >90 % bei der Überwachung rotierender Maschinen erreichen.

Lernalgorithmen könnten auf vielfältige Weise zur Verbesserung der Genauigkeit und Zuverlässigkeit von IoT-Lokalisierungssystemen eingesetzt werden. Einige dieser Anwendungen sind wie folgt zusammengefasst:

- **Kalibrierung:** Lernalgorithmen können zur Kalibrierung von Sensoren und anderen IoT-Gerätekomponenten verwendet werden, um sicherzustellen, dass diese korrekt funktionieren und genaue Daten liefern. Dies kann dazu beitragen, die Gesamtgenauigkeit der Standortschätzungen zu verbessern. [65]
- **Rauschunterdrückung:** Algorithmen des maschinellen Lernens können verwendet werden, um Rauschen und andere Fehlerquellen aus Daten von IoT-Geräten zu entfernen. Dies kann dazu beitragen, die Genauigkeit von Standortschätzungen zu verbessern, indem die Auswirkungen von Fehlern und anderen Faktoren, die die Daten verzerren können, reduziert werden. Algorithmen des maschinellen Lernens können verwendet werden, um die relevantesten Merkmale in von IoT-Geräten gesammelten Daten zu identifizieren, wodurch die Genauigkeit der Standortschätzung verbessert wird, indem sich auf die wichtigsten Faktoren konzentriert wird. [49]
- **Modellauswahl:** Algorithmen des maschinellen Lernens können verwendet werden, um das beste Modell oder die beste Kombination von Modellen für eine bestimmte Anwendung zu identifizieren, wodurch die Genauigkeit der Standortschätzung verbessert wird, indem das beste Modell ausgewählt wird, das zu den Daten passt. [34]
- **Verbesserung der Genauigkeit:** Große Datenmengen können von Algorithmen des maschinellen Lernens analysiert werden, um genauere Schätzungen des Gerätestandorts zu liefern. [33]
- **Automatisierung des Lokalisierungsprozesses:** Maschinelles Lernen hat das Potenzial, den Prozess der Bestimmung des Gerätestandorts zu automatisieren und somit die Notwendigkeit manueller Eingaben zu eliminieren.
- **Anpassung an Umgebungsveränderungen:** Um genauere Standortschätzungen zu liefern, können sich Algorithmen des maschinellen Lernens an Umgebungsveränderungen anpassen, wie z.B. neue Hindernisse oder Änderungen der Signalstärke. [51]

In einer Studie untersuchten Forscher die Rauschunterdrückung und Auflösungsverbesserung in der PET-Bildgebung. Die Positronen-Emissions-Tomographie (PET)-Bildgebung steht vor inhärenten Herausforderungen im Zusammenhang mit Rauschen und räumlicher Auflösung, die die quantitative Genauigkeit in der medizinischen Diagnostik beeinflussen. Traditionelle Techniken, wie die quadratische Straffung und die Gaußsche Filterung, wurden zur Minderung dieser Probleme eingesetzt. KI-basierte Methoden, insbesondere Convolutional Neural Networks (CNNs), haben jedoch die PET-Bildverarbeitung transformiert, indem sie direkte Abbildungen zwischen verrauschten und sauberen Bildern lernen. [64]

Moderne Architekturen umfassen:

- **3D-CNN-Modelle:** Bieten trotz hoher Rechenanforderungen überlegene Leistung.
- **Hybride 2D-3D-Netzwerke:** Integrieren dimensionale Merkmale für bessere Ergebnisse.
- **Unüberwachtes und selbstüberwachtes Lernen:** Nutzen Populationsmerkmale zur Verfeinerung verrauschter Daten. [19]

Aufkommende Paradigmen, wie föderiertes Lernen für den Datenschutz in mehreren Zentren und Reinforcement Learning für die adaptive Verarbeitung, verbessern die Zuverlässigkeit der PET-Bildgebung weiter. Da KI-gesteuerte Techniken sich ständig weiterentwickeln, werden Transferlernen, Datenharmonisierung und erklärbare KI entscheidende Rollen bei der Erzielung klinisch signifikanter Verbesserungen spielen.

KI-gesteuerte Entrauschungstechniken in der PET-Bildgebung basieren überwiegend auf überwachtem Lernen, wobei 3D-U-Net-Architekturen weit verbreitet sind. Diese Modelle verwenden typischerweise einen L2-Verlust, oft kombiniert mit perzeptuellen oder adversariellen Zielen, um die Bildklarheit und diagnostische Genauigkeit zu verbessern. [64]

Herausforderungen und zukünftige Richtungen Trotz ihres Erfolgs steht die KI-gesteuerte PET-Entrauschung vor Problemen der Generalisierbarkeit, hohen Rechenanforderungen und potenzieller GAN-bedingter Überglättung. Das Feld verschiebt sich hin zu hybriden Architekturen, die multimodale Daten und physikalische Einschränkungen für eine verbesserte klinische Anwendbarkeit integrieren. [64]

3.2.2 Sensorkalibrierung

Da die Messtechnik ein integraler Bestandteil der Automatisierung, Robotik und industriellen Systeme wird, wächst der Bedarf an präzisen und adaptiven Sensordaten. Sensoren unterliegen jedoch Fehlern aufgrund von Umgebungsveränderungen, Alterung und Signalrauschen, wodurch traditionelle Kalibrierungsmethoden – die oft manuell und statisch sind – für Echtzeitanwendungen unzureichend werden.

Deep Learning transformiert die Sensorkalibrierung durch:

- **Modellierung nichtlinearer Beziehungen** zwischen Rohsensorausgaben und wahren Werten.
- **Ermöglichung kontinuierlicher, In-situ-Kalibrierung** ohne Betriebsunterbrechung.
- **Verbesserung der Genauigkeit** bei gleichzeitiger Reduzierung der Wartungskosten.

Die neuronale netzbasierte Kalibrierung ist besonders nützlich in der Industrieautomation, autonomen Fahrzeugen und Präzisionsfertigung und bietet

skalierbare und adaptive Lösungen. Dieser Abschnitt wird Schlüsseltechniken, Architekturen und reale Anwendungen untersuchen, die KI für eine verbesserte Sensorkalibrierungsleistung unter dynamischen Bedingungen nutzen. [5]

Eine der wichtigsten Kalibrierungsmethoden sind Drahtlose Sensornetzwerke (WSNs), die für die Umweltüberwachung, intelligente Städte und Präzisionslandwirtschaft von entscheidender Bedeutung sind und Echtzeit-Raum- und Zeitmessungen ermöglichen. Sensor-Drift – eine allmähliche Abweichung von genauen Messwerten aufgrund von Umgebungsveränderungen oder Hardwareverschleiß – stellt jedoch eine große Herausforderung bei großflächigen Implementierungen dar, bei denen eine manuelle Neukalibrierung unpraktisch ist. Traditionelle Blind-Kalibrierungsmethoden basieren auf festen Annahmen wie linearen Signalsubräumen oder dichter Sensorplatzierung, was die Anpassungsfähigkeit einschränkt. [39]

PRNet: KI-gesteuerte Sensorkalibrierung PRNet (Projection-Recovery Network) ist ein tiefes, vollständig faltendes Netzwerk, das entwickelt wurde, um die Blind-Kalibrierung in WSNs zu automatisieren und wichtige Herausforderungen zu bewältigen:

- **Merkmalextraktion ohne vorherige Modelle:** Im Gegensatz zu unterraumgestützten Methoden, die Linearität annehmen, lernt PRNet räumlich-zeitliche Korrelationen direkt aus Sensordaten. Es verwendet eine Projektionsschicht, um Driftkomponenten zu isolieren, und Wiederherstellungsschichten, um saubere Signale zu rekonstruieren.
- **Dateneffizienz:** Um begrenzte reale Trainingsdaten zu überwinden, synthetisiert PRNet Trainingsbeispiele, indem es kurzfristige Messungen nach der Bereitstellung mit simulierten Driftmustern erweitert.

Methodik & Architektur

- **Projektionsschicht:** Bildet verdriftete Messungen in einen Merkmalsraum ab, in dem Drift und Signal trennbar sind.
- **Wiederherstellungsschichten:** Führen extrahierte Merkmale zusammen, um die Drift abzuschätzen, während Batch-Normalisierung für stabiles Training verwendet wird.
- **Sensormanipulation:** Optimiert die Eingabetensorstruktur durch Neuordnung benachbarter Sensoren, um lokale Korrelationen zu verbessern.
- **Verlustfunktionen & Augmentierung:** Kombiniert Projektionsverlust mit Wiederherstellungsverlust. Driftfreie Segmente werden mit synthetischen Rauschmodellen gestört, um diverse Trainingsbeispiele zu generieren. [13]

Experimente & Ergebnisse

- **Testumgebung:** 6 Sensoreinheiten, jede mit 4 Sensoren, kalibriert gegen hochpräzise Thermometer.
- **Simulierte Daten:** Nichtlineares Sensorfeld mit kontrollierten Drifteinspeisungen.

- **Leistungshighlights:**
 - PRNet stellt doppelt so viele verdriftete Sensoren wieder her wie SPSR-TSBL (80 % Wiederherstellungsrate).
 - Übertrifft SVR-KF (vorhersagebasierter Ansatz) unter rauschigen und nichtlinearen Bedingungen.
 - Generalisiert auf ungesehene Drift-Typen (z.B. Schrittdrift, variierende Rauschpegel). [38]

3.2.3 Mustererkennung

In der Messtechnik verbessert die Mustererkennung durch KI nicht nur die Dateninterpretation, sondern ermöglicht auch Echtzeitüberwachung, prädiktive Diagnosen und intelligente Steuerungsstrategien. Dieser Abschnitt untersucht Schlüsselansätze zur Mustererkennung aus Sensordaten, erforscht repräsentative Architekturen neuronaler Netze und hebt deren Auswirkungen in Branchen wie dem Gesundheitswesen, Automobilsystemen und der Industrieüberwachung hervor.

Computer Vision (CV) und Machine Vision (MV) revolutionieren die Industrieautomation, insbesondere in der Qualitätskontrolle, wo Präzision, Effizienz und Echtzeitleistung entscheidend sind. Mit fortschreitender Industrie 4.0 bietet die Integration von CV mit KI, IoT und Cloud Computing neue Möglichkeiten, stellt aber auch Herausforderungen in Bezug auf Skalierbarkeit und Anpassungsfähigkeit dar. [43]

Schlüsseltechnologien in der industriellen Computer Vision

- **Maschinelles Lernen & Deep Learning:** ML ermöglicht die automatisierte Fehlererkennung durch regelbasierte Klassifikatoren und CNNs. CNNs, die in der Mustererkennung weit verbreitet sind, ahmen das menschliche Sehen für Aufgaben wie Objektklassifizierung und Fehleridentifikation nach.
- **Farbbasierte Inspektion:** Die industrielle Qualitätskontrolle stützt sich auf RGB-Codierung und hyperspektrale Bildgebung, um Farbinconsistenzen zu erkennen, die oft auf Produktfehler oder Verderb hinweisen.
- **Design von Machine-Vision-Systemen (MVS) [44]:**
 - **Beleuchtung:** Techniken wie polarisierte Beleuchtung verbessern die Bildgebung mit hohem Kontrast.
 - **Bilderfassung:** CMOS- und CCD-Sensoren übersetzen visuelle Daten in messbare Fehlergrößen.
 - **Verarbeitung:** Kantenerkennung, binäre Schwellenwertbildung und Konturanalyse verbessern die Präzision der automatisierten Inspektion.

Industrielle Anwendungen [44]

- **Echtzeit-Qualitätsüberwachung:** Ein robotergestütztes Beton-Drucksystem verwendet Gaußsche Filterung, um Extrusionsfehler zu erkennen, und erreicht dabei Submillimeterpräzision.

- **Bolzen- und Schraubeninspektion mit KI:** Ein CNN-gesteuertes System, das auf Edge-Geräten eingesetzt wird, klassifiziert Fehler mit >95 % Genauigkeit und verwendet Graustufenkonvertierung und Kantenerkennung, um eine automatische Ausschussauslösung zu bewirken.

Zukünftige Richtungen in der Computer Vision für die Industrie [44]

- **Föderiertes Lernen:** Behebt Datenknappheit durch Aggregation verteilter Erkenntnisse unter Wahrung der Privatsphäre.
- **Erklärbare KI (XAI):** Verbessert das Vertrauen in KI-gesteuerte Entscheidungen durch Integration von Aufmerksamkeitskarten für die Interpretierbarkeit.
- **Multimodale Sensorfusion:** Die Kombination von thermischer und Röntgenbildgebung verbessert die Fehlererkennung in komplexen Strukturen.

3.2.4 Anomalieerkennung in Messungen

Im Rahmen der KI in der Messtechnik spielt die Anomalieerkennung eine Schlüsselrolle bei der vorausschauenden Wartung, Qualitätssicherung und Fehlerdiagnose. Dieser Abschnitt untersucht, wie moderne KI-Modelle zur Verbesserung der Anomalieerkennung in sensorbasierten Systemen eingesetzt werden, welche Architekturen am häufigsten angewendet werden und wie diese Methoden die Zuverlässigkeit und Betriebseffizienz in einer Reihe von Branchen verbessern.

Anomalieerkennung ist in Bereichen wie Cybersicherheit, Gerätewartung, Betrugserkennung und Gesundheitsüberwachung von entscheidender Bedeutung, wo die Identifizierung von Abweichungen von erwarteten Mustern die Systemzuverlässigkeit gewährleistet. Trotz ihrer breiten Anwendbarkeit behindern methodische Inkonsistenzen in der Anomalieerkennungsforschung – wie z.B. unterschiedliche Datenpartitionierungsstrategien, Metrikwahl und Implementierungsdetails – die Reproduzierbarkeit und faire Bewertung. [42]

Herausforderungen bei der Anomalieerkennung

- **Inkonsistente Datenteilung:** Unterschiedliche Partitionierungsmethoden beeinflussen die Modellleistung und Vergleichbarkeit.
- **Metrikvariabilität:** Metriken wie F1-Score, Präzision und Recall hängen von der Schwellenwertauswahl und dem Klassenungleichgewicht ab, was zu inkonsistenten Ergebnissen führt.
- **Implementierungslücken:** Unterschiede in der Datenvorverarbeitung wirken sich erheblich auf die gemeldete Genauigkeit aus.

Standardisierungsbemühungen und Ergebnisse Forscher plädieren für vereinheitlichte Protokolle, einschließlich des ausschließlichen Trainings auf normalen Daten, der Definition von Anomalien als positive Klasse und der Verwendung robuster Metriken

wie AUPR für eine verbesserte Anomalieerkennungsempfindlichkeit. Empirische Studien zeigen:

- Neu bewertete Modelle unterscheiden sich oft von früheren veröffentlichten Ergebnissen aufgrund inkonsistenter Bewertung.
- Einfache Modelle wie Vanilla-Autoencoder (DAE) können komplexere Architekturen übertreffen.
- Herausfordernde Datensätze (z.B. CSE-CIC-IDS2018) liefern aussagekräftigere Erkenntnisse als weit verbreitete, aber triviale Datensätze (z.B. KDD).

KI-basierte Anomalieerkennung in drahtlosen Sensornetzwerken (WSNs) WSNs spielen eine wichtige Rolle im Internet der Dinge (IoT), aber Sensoranomalien – verursacht durch Hardwarefehler, Umgebungsveränderungen oder Cyberangriffe – bedrohen die Datenzuverlässigkeit. Traditionelle zentralisierte Anomalieerkennung ist aufgrund hoher Datenübertragungskosten ineffizient, während verteilte Methoden oft unter hoher Rechenkomplexität oder übermäßiger Kommunikation zwischen Sensoren leiden.

Autoencoder-basierte Anomalieerkennung für WSNs Ein dreischichtiger Autoencoder komprimiert und rekonstruiert Sensordaten, um Anomalien auf der Grundlage von Rekonstruktionsfehlern zu erkennen, wobei er ohne gelabelte Daten durch unüberwachtes Lernen arbeitet.

Verteilter Algorithmus-Ansatz

- **Sensor-Ebene (Edge Processing):** Jeder Sensor erkennt Anomalien lokal, indem er Eingabe- und rekonstruierte Werte vergleicht, ohne dass eine Kommunikation zwischen den Sensoren erforderlich ist.
- **Cloud-Ebene-Verarbeitung:** Aggregiert Residuen und aktualisiert globale Statistiken, wobei der Autoencoder regelmäßig neu trainiert wird, um die Genauigkeit zu erhalten und gleichzeitig den Sensor-Overhead zu reduzieren.

Vergleich verschiedener Ansätze zur Anomalieerkennung. [41]

Approach	Data Processing	Advantages	Limitations
Centralized	All sensor data is sent to a central server for anomaly detection.	- High accuracy due to large-scale processing. - Can effectively use deep learning models.	- High bandwidth usage. - Increased latency. - Privacy concerns.
k-NN (k-Nearest Neighbors)	Compares each new data point to its k closest neighbors.	- Simple and interpretable. - Works well with structured data.	- Computationally expensive for large datasets. - Sensitive to noisy data.
Autoencoder (Deep Learning)	Compresses and reconstructs sensor data, detecting anomalies via reconstruction error.	- Works well with high-dimensional data. - Adapts to new data patterns automatically. - Low communication overhead in distributed systems.	- Requires sufficient training data. - Can be difficult to interpret results. - Higher computational complexity compared to traditional methods.