

B. Grundlagen der Bildvorverarbeitung

Dieser Text erläutert die Grundlagen der Bildrepräsentation, wichtige Vorverarbeitungstechniken, die mathematischen Prinzipien der Kantenerkennung sowie deren Bedeutung für die Merkmalsextraktion in Convolutional Neural Networks (CNNs).

Grundlagen der digitale Bildrepräsentation: Pixel, Kanäle und Farbräume (RGB, HSV, Graustufen)

Dieser Abschnitt erläutert die grundlegenden Konzepte der digitalen Bilddarstellung, einschließlich der Rolle von Pixeln, Bildkanälen und Farbräumen.

1. Pixel: Die Bausteine digitaler Bilder

Ein Pixel (Bildpunkt) ist die kleinste Einheit eines digitalen Bildes. Es repräsentiert die Helligkeit oder Farbe an einer bestimmten Position im Bildraaster. Digitale Bilder werden als zweidimensionale Matrizen von Pixelwerten gespeichert (bzw. als dreidimensionale Matrizen bei Farbbildungen). [1]

In einem Graustufenbild mit 8 Bit pro Pixel nimmt jeder Pixel einen Wert zwischen 0 (schwarz) und 255 (weiß) an. Da zwischen liegende Werte stehen für verschiedene Grautöne. [1]

2. Kanäle: Farb- oder Intensitätsebenen

Ein Kanal beschreibt eine Schicht innerhalb eines mehrdimensionalen Bildes, die Intensitätswerte für eine bestimmte Komponente enthält. RGB-Bilder zum Beispiel bestehen aus drei Kanälen: Rot, Grün und Blau. Jeder Kanal ist eine separate Graustufenmatrix, die die jeweilige Farbintensität enthält. Durch das Kombinieren dieser drei Matrizen entsteht ein vollständiges Farbbild. Weitere Kanäle wie ein Alpha-Kanal (Transparenzinformation) oder spezielle Kanäle für Tiefen- oder Infrarotinformationen können ergänzt werden, je nach Anwendung. [2]

3. Farbräume: Mathematische Modelle der Farbdarstellung

Ein Farbraum legt fest, wie Farben numerisch beschrieben und interpretiert werden. Die Wahl des Farbraums kann die Effizienz und Genauigkeit vieler Bildverarbeitungsaufgaben maßgeblich beeinflussen. [2]

RGB (Rot, Grün, Blau)

Die meisten Farbbilder sind mit jeweils einer Komponente für die primär Farben Rot, Grün und Blau (RGB) kodiert, typischerweise mit 8 Bits pro Komponente. Jeder Pixel eines solchen Farbbilds besteht daher aus $3 \times 8 = 24$ Bits und der Wertebereich jeder Farbkomponente ist wiederum $[0, 255]$. [4]

Ein additives Farbmodell, bei dem verschiedene Intensitäten von Rot, Grün und Blau kombiniert werden, um andere Farben zu erzeugen. [3]

HSV (Farbton, Sättigung, Helligkeit)

Da sich Farbton (Hue), Farbsättigung (Saturation) und Helligkeit (Value Colour Intensity) bei jeder Koordinatenbewegung gleichzeitig ändern, ist auch die manuelle Auswahl von Farben im RGB-Raumschwierig und wenig intuitiv. Alternative Farbräume, wie z. B. der HSV-Raum, erleichtern diese Aufgabe, in dem subjektiv wichtige Farbeigenschaften explizit dargestellt werden. [3]

Es orientiert sich stärker an der menschlichen Farbwahrnehmung und es ist besonders nützlich für Anwendungen wie Farberkennung, Segmentierung oder Tracking bei wechselnden Lichtverhältnissen. [2]

Graustufen

Ein Bild kann als eine zweidimensionale Funktion $f(x, y)$ definiert werden, wobei x und y räumliche (ebene) Koordinaten sind und die Amplitude von f an einem beliebigen Koordinatenpaar (x, y) als Intensität oder Grauwert des Bildes an diesem Punkt bezeichnet wird. Wenn x, y und die Intensitätswerte von f alle endlichen, diskreten Größen sind, spricht man von einem digitalen Bild. [2]

Bildvorverarbeitungstechniken: Normalisierung, Filterung (Gauß, Median), Histogrammausgleich

Die Bildvorverarbeitung ist ein zentraler Schritt in der digitalen Bildverarbeitung, da sie die Qualität und Nutzbarkeit von Bilddaten für nachfolgende Analyseverfahren verbessert.

1. Normalisierung

Die Normalisierung (auch Standardisierung genannt) bezeichnet die Umwandlung der Pixelwerte eines Bildes in einen festgelegten Wertebereich (z. B. von $[0, 255]$ auf $[0, 1]$) oder die Anpassung auf einen Mittelwert von 0 und eine Standardabweichung von 1. Ziel dieser Maßnahme ist es, eine einheitliche Darstellung der Daten zu erreichen, um die Leistung und Konvergenzgeschwindigkeit von Lernalgorithmen – insbesondere neuronalen Netzen – zu verbessern. Große Unterschiede in der Skalierung können zu schlechteren Ergebnissen beim Training führen. [4]

Gängige Methoden:

Min-Max-Normalisierung

Diese Methode transformiert jeden Pixelwert xxx nach der Formel:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (2.2.1)$$

Sie skaliert die Daten auf einen festen Bereich – in der Regel $[0, 1]$. Diese Methode ist effizient, aber empfindlich gegenüber Ausreißern. [5]

Z-Score-Normalisierung (Standardisierung)

Hierbei werden die Daten so transformiert, dass sie einen Mittelwert von 0 und eine Standardabweichung von 1 aufweisen. Die Formel lautet:

$$z = \frac{x - \mu}{\sigma} \quad (2.2.2)$$

wobei μ der Mittelwert und σ die Standardabweichung ist. Diese Methode ist robuster gegenüber Ausreißern und eignet sich besonders, wenn Merkmale unterschiedliche Einheiten oder Skalen aufweisen. [5]

Diese Normalisierungsverfahren sind grundlegende Schritte der Bildvorverarbeitung und spielen eine entscheidende Rolle bei der Verbesserung der Stabilität und Effizienz von Lernalgorithmen.

2. Filterung: Gauß- und Medianfilter

Die Filterung ist eine Technik zur Rauschunterdrückung oder Glättung von Bilddaten. Dabei werden die Pixelwerte durch die lokale Nachbarschaft ersetzt oder modifiziert. [2]

Zwei besonders verbreitete Filtertypen sind:

Gaußfilter

Ein Gaußfilter wendet eine gewichtete Mittelung basierend auf der Gaußschen Verteilung an. Er ist ideal zur Reduktion von hochfrequentem Rauschen, da er weiche Übergänge erzeugt und gleichzeitig Bildkanten weitgehend erhält. Mathematisch entspricht der Filter einer Faltung mit einer zweidimensionalen Gaußfunktion:

$$H^{G,\sigma}(x,y) = e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (2.2.3)$$

[3]

Ein zweidimensionales Gaußfilter kann als Hintereinander Ausführung zweier eindimensionaler Gaußfilter formuliert werden, was eine effiziente Berechnung ermöglicht. [3]

Medianfilter

Der Medianfilter ist ein nicht-linearer Filter, der jeden Pixel durch den Medianwert seiner Nachbarschaft ersetzt:

$$I(u,v) \leftarrow \text{median} (I(u+i,v+j) \mid (i,j) \in R). \quad (2.2.4)$$

Er ist besonders effektiv zur Beseitigung von Impulsrauschen, ohne dabei Kanten zu stark zu glätten. [3]

3. Histogramm Ausgleich (Histogram Equalization)

Der Histogramm Ausgleich ist eine Technik zur Kontrastverbesserung, bei der die Helligkeitsverteilung eines Bildes gestreckt oder angepasst wird, sodass möglichst viele Intensitätsstufen gleichmäßig genutzt werden. Dadurch werden Details in dunklen oder hellen Bildbereichen besser sichtbar. Das Verfahren basiert auf der kumulativen Verteilungsfunktion des Histogramms.[2]

Unter Berücksichtigung kontinuierlicher Intensitätswerte. Die Variable r gibt die Intensitäten eines zu verarbeitenden Bildes an. Angenommen, r liegt im Bereich $[0, L-1]$, wobei $r = 0$ Schwarz und Weiß darstellt. [2]

In der Praxis wird das Histogramm des Bildes analysiert und durch Transformation der Grauwerte neu verteilt:

$$s_k = (L-1) \sum_{j=0}^k p_r(r_j) \quad (2.2.5)$$

[2]

Mathematische Grundlagen der Kantendetektion: Faltung, Gradientenoperatoren (Sobel, Prewitt), Laplace-Operator

Die Kantendetektion ist ein grundlegender Bestandteil der Bildverarbeitung und Computer Vision, da sie zentrale Informationen über die Struktur eines Bildes liefert. Die mathematische Basis umfasst die Faltung (*Convolution*), Gradientenoperatoren ...

1. Korrelation und Faltung (Convolution)

Korrelation ist der Vorgang, bei dem eine Filtermaske über das Bild bewegt und die Summe der Produkte an jeder Stelle berechnet wird, genau wie im vorherigen Abschnitt erläutert. Die Mechanik der Faltung ist dieselbe, außer dass der Filter zunächst um 180° gedreht wird.[2]

Die Faltung ist eine zentrale mathematische Operation in der Bildverarbeitung. Sie verknüpft zwei Funktionen gleicher Dimensionalität, kontinuierlich oder diskret. Für diskrete, zweidimensionale Funktionen I und H ist die Faltungsoperation definiert als:

$$I' (u, v) = \sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} I(u-i, v-j) H(i, j) \quad 2.2.6$$

[3]

Sie dient als Grundlage für viele Operationen, darunter Glättung, Rauschunterdrückung und insbesondere Kantendetektion. [3]

2. Gradientenoperatoren: Sobel und Prewitt

Zwei klassische Verfahren sind die Kantenoperatoren von Prewitt und Sobel, die einander sehr ähnlich sind und sich nur durch geringfügig abweichende Gradientenfilter unterscheiden. [3]

Prewitt-Operator

Der Prewitt-Operator verwendet einfache 3×3-Masken, um horizontale und vertikale Kanten zu erfassen:

$$H_x = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix} \text{ und } H_y = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad (2.2.7)$$

[2]

Sobel-Operator

Die Filter des Sobel-Operators sind fast identisch, geben allerdings durch eine etwas andere Glättung mehr Gewicht auf die zentrale Zeile bzw. Spalte:

$$H_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \text{ und } H_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad (2.2.8)$$

[2]

3. Laplace-Operator

Für die Kantenschärfung im zweidimensionalen Fall verwendet man die zweiten Ableitungen in horizontaler und vertikaler Richtung kombiniert in Form des so genannten Laplace-Operators:

$$(\nabla^2 f)(x, y) = \frac{\partial^2 f}{\partial^2 x}(x, y) + \frac{\partial^2 f}{\partial^2 y}(x, y) \quad (2.2.9)$$

[3]

Typische Laplace-Masken (diskret) sind z. B.:

$$H = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix} \quad (2.2.10)$$

[3]

Die Rolle der Kantendetektion in der Merkmalsextraktion und ihre Bedeutung für die Leistung von CNNs

1. Bedeutung der Kantendetektion für die Merkmalsextraktion

Kanten repräsentieren abrupte Änderungen in der Intensität eines Bildes und markieren damit Objektgrenzen, Texturen oder Formübergänge. Bei der Merkmalsextraktion geht es darum, aus Rohdaten (z. B. einem Bild) charakteristische Informationen zu extrahieren, die zur Erkennung oder Klassifikation verwendet werden können. [2]

Kanten liefern:

- lokalisierte Strukturinformationen (z. B. Umrisse, Konturen),
- reduzierte Datenkomplexität durch Fokus auf relevante Regionen,
- Invarianz gegenüber Helligkeit und Farbe, da sie meist nur von Intensitätsänderungen abhängig sind.

[2]

2. Rolle in Convolutional Neural Networks (CNNs)

Convolutional Neural Networks (CNNs) lernen Merkmale in hierarchischen Schichten. In den frühen Schichten eines CNNs erkennen die Filter typischerweise einfache Muster – vor allem Kanten in verschiedenen Richtungen.

Diese Kantenmuster bilden die Grundlage für:

- die Lokalisation von Objekten,
- die Erkennung von Formen und Texturen in späteren Schichten,
- die Reduktion von Redundanz, da irrelevante Informationen verworfen werden.

[6]